Inferencia e introducción a los modelos estadísticos con R

Curso intersemestral de Invierno - Posgrado de Ciencias Políticas y Sociales

Ana Escoto

1/9/23

Table of contents

Introducción al curso

Objetivo general

Que el estudiantado sea capaz de realizar inferencia estadística y modelado de una variable dependiente utilizando R aplicado a las bases de datos mexicanas.

Temas

1. Revisión de elementos estadísticos básicos desde "tidyverse"

a. Tablas de múltiples entradas

b. Repaso de ggplot2

2. Pruebas de hipótesis e intervalos de confianza

a. De una sola media

b. De dos medias

c. Medias apareadas

d. Proporciones

e. Diferencia de proporciones

f. Chi-cuadrado de independencia

g. Prueba ANOVA de un solo factor

h. Pruebas no parámetricas

3. Factores de expansión y diseño muestral complejo

a. De “survey” a “srvyr”

b. Tabulados

c. Intervalos de confianza para medias y cuantiles

4. Introducción al modelo de regresión lineal

a. Simple

b. Múltiple

c. Evaluación de supuestos

5. Introducción a los modelos lineales generalizados

a. Introducción a la regresión logística

b. Evaluación de supuestos

c. Efectos marginales

d. Interacciones y efectos de más de primer orden

Metodología

La metodología del curso consistirá en lo siguiente:

1. La exposición de la facilitadora. Durante la primera parte de la sesión, se expondrán los comandos necesarios para llevar a cabo cada tema. Se dará una introducción sobre la temática y se buscará dar ejemplos concretos para facilitar el aprendizaje. Se espera que el personal exponga sus dudas o comentarios a lo largo de la explicación.

2. Realización de ejercicios prácticos. Al final de cada sesión, corresponderá a las personas asistentes del curso realizar individualmente o en parejas un ejercicio relacionado con lo visto en la primera parte de la clase.

3. Consulta autónoma de material. Tanto la exposición como los ejercicios serán acompañado de material de consulta realizado ad hoc para el curso y el contenido, de tal manera que el estudiantado pueda volver a los códigos y las explicaciones posteriormente.

Proyecto en posit.cloud

https://posit.cloud/content/5191591

Con este proyecto se trabajará a lo largo del curso

Versiones anteriores

Esta es la tercera vez que se imparte el curso. Las versiones anteriores están

- https://aniuxa.github.io/posgrado_modelo/
- https://aniuxa.github.io/posgrado_modelo2/

Facilitadora

Ana Ruth Escoto Castillo

Doctora en Estudios de Población. Centro de Estudios Demográficos y Urbanos, El Colegio de México.

Semblanza

Profesora de tiempo completo en la Facultad de Ciencias Políticas y Sociales. Investigadora nivel I en elSistema Nacional de Investigadores. Maestra en Población y Desarrollo por la Facultad Latinoamericana de Ciencias Sociales (FLACSO) – Sede México. Posee experiencia en recolección de información estadística, diseño y control de procesos de recolección y su procesamiento. Ha aplicado diversos métodos y herramientas multivariadas, homologación de información y comparabilidad de fuentes en sus investigaciones, así como usa de diversos softwares estadísticos, y ha impartido clases de estadítica aplicada a nivel de licenciatura y posgrado. Es co-coordinadora del Capítulo de CDMX de la iniciativa RLadies.

Bibliografía

Básica

Escoto Castillo, A. R. (2021). ¿Cómo empezar a estudiar el mercado de trabajo en México? Una introducción al análisis estadístico con R aplicado a la Encuesta Nacional de Ocupación y Empleo. Ciudad de México: Universidad Nacional Autónoma de México.

Wickham, H., & Grolemund, G. (2016). R for data science: Import, tidy, transform, visualize, and model data. O'Reilly Media, Inc.

- Español
- Inglés

Fundamentos estadísticos

- Hardy, M. A., & Bryman, A. (Eds.). (2009). Handbook of data analysis. SAGE.
- Hazelrigg, L. (2009). Inference. En M. A. Hardy & A. Bryman (Eds.), Handbook of data analysis (pp. 65–111). SAGE.
- Mendenhall, W., Beaver, R. J., & Beaver, B. M. (2014). Introducción a la probabilidad y estadística (J. A. Velázquez Arellano, Trad.).
- Moore, D. S. (2004). The basic practice of statistics (3rd ed). W.H. Freeman.
- Wooldridge, J. (2010). Introducción a la Econometría. 4e. Cengage Learning Editores S.A. de C.V. http://public.eblib.com/choice/publicfullrecord.aspx?p=4641575

Instalación de R y Rstudio

Introducción a R

https://youtu.be/YkN5urybh2A

Instalación en OS

https://youtu.be/icWV8jzYOtA

Instalación en PC

https://youtu.be/TNSQikMfgJI

Ojo

Desde octubre de 2022, RStudio se volvió **"Posit"**

Chapter 1

Introducción: {dplyr}

1.1 Paquetes

```
if (!require("pacman")) install.packages("pacman")#instala pacman si se requiere
```

```
Loading required package: pacman
```

```
pacman::p_load(tidyverse,
               readxl,
               writexl,
               haven,
               sjlabelled,
               janitor,
               infer,
               ggpubr,
               magrittr,
               gt)
```

1.2 Cargando los datos

Desde STATA

```
tlaxt322<- haven::read_dta("./datos/tlaxt322.dta")
```

Desde Excel:

```
ICI_2021 <- readxl::read_excel("./datos/ICI_2021.xlsx",
                               sheet = "para_importar")
```

```
New names:
* `` -> `...2`
```

1.3 Un poquito de {dplyr} y limpieza

1.3.1 Primero, los pipes

R utiliza dos pipes el nativo |> y el pipe que está en {dplyr} %>%. Algunas de las diferencias las puedes checar acá https://eliocamp.github.io/codigo-r/2021/05/r-pipa-nativa/

En estas prácticas utilizaremos el segundo, pero son muy parecidos y para que esta instructora recicle algunos de sus códigos viejos. Pero funcionan igual:

```
tlaxt322|> #pipe nativo, no necesita instalación
  head()
```

```
# A tibble: 6 x 114
  r_def           loc   mun   est est_d~1 est_d~2  ageb t_loc~3 t_loc~4 cd_a
  <dbl+lbl>     <dbl> <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl+l> <dbl+l> <dbl+lb>
1 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
2 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
3 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
4 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
5 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
6 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
# ... with 104 more variables: ent <dbl+lbl>, con <dbl>, upm <dbl>,
#   d_sem <dbl+lbl>, n_pro_viv <dbl>, v_sel <dbl+lbl>, n_hog <dbl+lbl>,
#   h_mud <dbl+lbl>, n_ent <dbl+lbl>, per <dbl+lbl>, n_ren <dbl+lbl>,
#   c_res <dbl+lbl>, par_c <dbl>, sex <dbl+lbl>, eda <dbl>, nac_dia <dbl+lbl>,
#   nac_mes <dbl+lbl>, nac_anio <dbl>, l_nac_c <dbl+lbl>, cs_p12 <dbl+lbl>,
#   cs_p13_1 <dbl+lbl>, cs_p13_2 <dbl+lbl>, cs_p14_c <chr>, cs_p15 <dbl+lbl>,
#   cs_p16 <dbl+lbl>, cs_p17 <dbl+lbl>, n_hij <dbl+lbl>, e_con <dbl+lbl>, ...
```

```
tlaxt322 %>%  #pipe de dplyr, necesita instalación de dplyr en tidyverse
  head()
```

```
# A tibble: 6 x 114
  r_def           loc   mun   est est_d~1 est_d~2  ageb t_loc~3 t_loc~4 cd_a
  <dbl+lbl>     <dbl> <dbl> <dbl>   <dbl>   <dbl> <dbl> <dbl+l> <dbl+l> <dbl+lb>
1 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
2 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
3 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
4 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
5 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
6 0 [Entrevist~    NA    31    20     413      NA     0 2 [Loc~ NA      39 [Tla~
# ... with 104 more variables: ent <dbl+lbl>, con <dbl>, upm <dbl>,
#   d_sem <dbl+lbl>, n_pro_viv <dbl>, v_sel <dbl+lbl>, n_hog <dbl+lbl>,
#   h_mud <dbl+lbl>, n_ent <dbl+lbl>, per <dbl+lbl>, n_ren <dbl+lbl>,
#   c_res <dbl+lbl>, par_c <dbl>, sex <dbl+lbl>, eda <dbl>, nac_dia <dbl+lbl>,
#   nac_mes <dbl+lbl>, nac_anio <dbl>, l_nac_c <dbl+lbl>, cs_p12 <dbl+lbl>,
#   cs_p13_1 <dbl+lbl>, cs_p13_2 <dbl+lbl>, cs_p14_c <chr>, cs_p15 <dbl+lbl>,
#   cs_p16 <dbl+lbl>, cs_p17 <dbl+lbl>, n_hij <dbl+lbl>, e_con <dbl+lbl>, ...
```

1.3.2 Limpieza de nombres con {janitor}

Este paso también nos permitirá enseñar otro *pipe* que está en el paquete {magrittr}.

Los nombres de una base de datos son los nombres de las columnas.

```
names(tlaxt322)
```

```
  [1] "r_def"      "loc"        "mun"        "est"        "est_d_tri"
  [6] "est_d_men"  "ageb"       "t_loc_tri"  "t_loc_men"  "cd_a"
 [11] "ent"        "con"        "upm"        "d_sem"      "n_pro_viv"
 [16] "v_sel"      "n_hog"      "h_mud"      "n_ent"      "per"
 [21] "n_ren"      "c_res"      "par_c"      "sex"        "eda"
 [26] "nac_dia"    "nac_mes"    "nac_anio"   "l_nac_c"    "cs_p12"
 [31] "cs_p13_1"   "cs_p13_2"   "cs_p14_c"   "cs_p15"     "cs_p16"
 [36] "cs_p17"     "n_hij"      "e_con"      "cs_p20a_1"  "cs_p20a_c"
 [41] "cs_p20b_1"  "cs_p20b_c"  "cs_p20c_1"  "cs_ad_mot"  "cs_p21_des"
 [46] "cs_ad_des"  "cs_nr_mot"  "cs_p23_des" "cs_nr_ori"  "ur"
 [51] "zona"       "salario"    "fac_tri"    "fac_men"    "clase1"
 [56] "clase2"     "clase3"     "pos_ocu"    "seg_soc"    "rama"
 [61] "c_ocu11c"   "ing7c"      "dur9c"      "emple7c"    "medica5c"
 [66] "buscar5c"   "rama_est1"  "rama_est2"  "dur_est"    "ambito1"
 [71] "ambito2"    "tue1"       "tue2"       "tue3"       "busqueda"
 [76] "d_ant_lab"  "d_cexp_est" "dur_des"    "sub_o"      "s_clasifi"
 [81] "remune2c"   "pre_asa"    "tip_con"    "dispo"      "nodispo"
 [86] "c_inac5c"   "pnea_est"   "niv_ins"    "eda5c"      "eda7c"
 [91] "eda12c"     "eda19c"     "hij5c"      "domestico"  "anios_esc"
```

```
 [96] "hrsocup"    "ingocup"    "ing_x_hrs"  "tpg_p8a"    "tcco"
[101] "cp_anoc"    "imssissste" "ma48me1sm"  "p14apoyos"  "scian"
[106] "t_tra"      "emp_ppal"   "tue_ppal"   "trans_ppal" "mh_fil2"
[111] "mh_col"     "sec_ins"    "tipo"       "mes_cal"
```

```
names(ICI_2021)
```

```
 [1] "País"
 [2] "...2"
 [3] "Protección de derechos humanos"
 [4] "Homicidios dolosos"
 [5] "Confianza en la policía"
 [6] "Independencia del poder judicial"
 [7] "Protección de derechos de propiedad"
 [8] "Tiempo para resolver quiebras"
 [9] "Cumplimiento de contratos"
[10] "Índice de Estado de Derecho"
[11] "Índice de Paz Global"
[12] "Contaminación del aire"
[13] "Emisiones de CO2"
[14] "Recursos hídricos renovables"
[15] "Áreas naturales protegidas"
[16] "Superficie forestal perdida"
[17] "Uso de pesticidas"
[18] "Fuentes de energía no contaminantes"
[19] "Índice de vulnerabilidad a efectos del cambio climático"
[20] "Índice de Gini"
[21] "Índice Global de Brecha de Género"
[22] "Mujeres en la PEA"
[23] "Dependientes de la PEA"
[24] "Acceso a agua potable"
[25] "Acceso a alcantarillado"
[26] "Analfabetismo"
[27] "Escolaridad promedio"
[28] "Calidad educativa"
[29] "Esperanza de vida"
[30] "Mortalidad infantil"
[31] "Cobertura de vacunación"
[32] "Médicos y médicas"
[33] "Gasto en salud per cápita"
[34] "Gasto en salud por cuenta propia"
[35] "Estabilidad política y ausencia de violencia"
[36] "Interferencia militar en el Estado de derecho o en el proceso político"
[37] "Libertades civiles"
```

```
[38] "Índice de Percepción de Corrupción"
[39] "Disponibilidad de información pública"
[40] "Participación electoral"
[41] "Equidad en los congresos"
[42] "Índice de efectividad del gobierno"
[43] "Miembro de la Alianza para el Gobierno Abierto"
[44] "Índice de desarrollo de Gobierno Electrónico"
[45] "Facilidad para abrir una empresa"
[46] "Tiempo para preparar y pagar impuestos"
[47] "Ingresos fiscales"
[48] "Finanzas sanas"
[49] "Carga impositiva"
[50] "Edad efectiva de retiro"
[51] "Flexibilidad de las leyes laborales"
[52] "Productividad media del trabajo"
[53] "Valor agregado de la industria"
[54] "Índice de transparencia y regulación de la propiedad privada"
[55] "Crecimiento del PIB"
[56] "Crecimiento promedio del PIB"
[57] "Inflación"
[58] "Inflación promedio"
[59] "Desempleo"
[60] "Deuda externa"
[61] "Calificación de deuda"
[62] "Reservas"
[63] "Libertad económica"
[64] "Índice Riesgos de seguridad energética"
[65] "Líneas móviles"
[66] "Usuarios de internet"
[67] "Servidores de internet seguros"
[68] "Flujo de pasajeros aéreos"
[69] "Índice de desempeño logístico (transporte)"
[70] "Tráfico portuario de contenedores"
[71] "Penetración del sistema financiero privado"
[72] "Capitalización del mercado de valores"
[73] "Socios comerciales efectivos"
[74] "Apertura comercial"
[75] "Diversificación de las exportaciones"
[76] "Diversificación de las importaciones"
[77] "Libertad comercial"
[78] "Inversión extranjera directa (neta)"
[79] "Inversión Extranjera Directa neta promedio"
[80] "Ingresos por turismo"
[81] "Gasto en investigación y desarrollo"
[82] "Coeficiente de invención"
[83] "Artículos científicos y técnicos"
```

```
[84] "Exportaciones de alta tecnología"
[85] "Índice de Complejidad Económica"
[86] "Empresas ISO 9001"
[87] "PIB en servicios"
[88] "0"
[89] "Inversión (FBCF)"
[90] "Talento"
```

Como vemos en las bases hay mayúsculas, caracteres especiales y demás. Esto lo podemos cambiar

```
ICI_2021<-ICI_2021 %>%
  janitor::clean_names()

names(ICI_2021)
```

```
 [1] "pais"
 [2] "x2"
 [3] "proteccion_de_derechos_humanos"
 [4] "homicidios_dolosos"
 [5] "confianza_en_la_policia"
 [6] "independencia_del_poder_judicial"
 [7] "proteccion_de_derechos_de_propiedad"
 [8] "tiempo_para_resolver_quiebras"
 [9] "cumplimiento_de_contratos"
[10] "indice_de_estado_de_derecho"
[11] "indice_de_paz_global"
[12] "contaminacion_del_aire"
[13] "emisiones_de_co2"
[14] "recursos_hidricos_renovables"
[15] "areas_naturales_protegidas"
[16] "superficie_forestal_perdida"
[17] "uso_de_pesticidas"
[18] "fuentes_de_energia_no_contaminantes"
[19] "indice_de_vulnerabilidad_a_efectos_del_cambio_climatico"
[20] "indice_de_gini"
[21] "indice_global_de_brecha_de_genero"
[22] "mujeres_en_la_pea"
[23] "dependientes_de_la_pea"
[24] "acceso_a_agua_potable"
[25] "acceso_a_alcantarillado"
[26] "analfabetismo"
[27] "escolaridad_promedio"
[28] "calidad_educativa"
[29] "esperanza_de_vida"
```

```
[30] "mortalidad_infantil"
[31] "cobertura_de_vacunacion"
[32] "medicos_y_medicas"
[33] "gasto_en_salud_per_capita"
[34] "gasto_en_salud_por_cuenta_propia"
[35] "estabilidad_politica_y_ausencia_de_violencia"
[36] "interferencia_militar_en_el_estado_de_derecho_o_en_el_proceso_politico"
[37] "libertades_civiles"
[38] "indice_de_percepcion_de_corrupcion"
[39] "disponibilidad_de_informacion_publica"
[40] "participacion_electoral"
[41] "equidad_en_los_congresos"
[42] "indice_de_efectividad_del_gobierno"
[43] "miembro_de_la_alianza_para_el_gobierno_abierto"
[44] "indice_de_desarrollo_de_gobierno_electronico"
[45] "facilidad_para_abrir_una_empresa"
[46] "tiempo_para_preparar_y_pagar_impuestos"
[47] "ingresos_fiscales"
[48] "finanzas_sanas"
[49] "carga_impositiva"
[50] "edad_efectiva_de_retiro"
[51] "flexibilidad_de_las_leyes_laborales"
[52] "productividad_media_del_trabajo"
[53] "valor_agregado_de_la_industria"
[54] "indice_de_transparencia_y_regulacion_de_la_propiedad_privada"
[55] "crecimiento_del_pib"
[56] "crecimiento_promedio_del_pib"
[57] "inflacion"
[58] "inflacion_promedio"
[59] "desempleo"
[60] "deuda_externa"
[61] "calificacion_de_deuda"
[62] "reservas"
[63] "libertad_economica"
[64] "indice_riesgos_de_seguridad_energetica"
[65] "lineas_moviles"
[66] "usuarios_de_internet"
[67] "servidores_de_internet_seguros"
[68] "flujo_de_pasajeros_aereos"
[69] "indice_de_desempeno_logistico_transporte"
[70] "trafico_portuario_de_contenedores"
[71] "penetracion_del_sistema_financiero_privado"
[72] "capitalizacion_del_mercado_de_valores"
[73] "socios_comerciales_efectivos"
[74] "apertura_comercial"
[75] "diversificacion_de_las_exportaciones"
```

```
[76] "diversificacion_de_las_importaciones"
[77] "libertad_comercial"
[78] "inversion_extranjera_directa_neta"
[79] "inversion_extranjera_directa_neta_promedio"
[80] "ingresos_por_turismo"
[81] "gasto_en_investigacion_y_desarrollo"
[82] "coeficiente_de_invencion"
[83] "articulos_cientificos_y_tecnicos"
[84] "exportaciones_de_alta_tecnologia"
[85] "indice_de_complejidad_economica"
[86] "empresas_iso_9001"
[87] "pib_en_servicios"
[88] "x0"
[89] "inversion_fbcf"
[90] "talento"
```

Si quisiéramos que la acción quedará de un solo, podemos usar un pipe diferente:

```
tlaxt322%<>%
  clean_names()

names(tlaxt322)
```

```
  [1] "r_def"      "loc"        "mun"        "est"        "est_d_tri"
  [6] "est_d_men"  "ageb"       "t_loc_tri"  "t_loc_men"  "cd_a"
 [11] "ent"        "con"        "upm"        "d_sem"      "n_pro_viv"
 [16] "v_sel"      "n_hog"      "h_mud"      "n_ent"      "per"
 [21] "n_ren"      "c_res"      "par_c"      "sex"        "eda"
 [26] "nac_dia"    "nac_mes"    "nac_anio"   "l_nac_c"    "cs_p12"
 [31] "cs_p13_1"   "cs_p13_2"   "cs_p14_c"   "cs_p15"     "cs_p16"
 [36] "cs_p17"     "n_hij"      "e_con"      "cs_p20a_1"  "cs_p20a_c"
 [41] "cs_p20b_1"  "cs_p20b_c"  "cs_p20c_1"  "cs_ad_mot"  "cs_p21_des"
 [46] "cs_ad_des"  "cs_nr_mot"  "cs_p23_des" "cs_nr_ori"  "ur"
 [51] "zona"       "salario"    "fac_tri"    "fac_men"    "clase1"
 [56] "clase2"     "clase3"     "pos_ocu"    "seg_soc"    "rama"
 [61] "c_ocu11c"   "ing7c"      "dur9c"      "emple7c"    "medica5c"
 [66] "buscar5c"   "rama_est1"  "rama_est2"  "dur_est"    "ambito1"
 [71] "ambito2"    "tue1"       "tue2"       "tue3"       "busqueda"
 [76] "d_ant_lab"  "d_cexp_est" "dur_des"    "sub_o"      "s_clasifi"
 [81] "remune2c"   "pre_asa"    "tip_con"    "dispo"      "nodispo"
 [86] "c_inac5c"   "pnea_est"   "niv_ins"    "eda5c"      "eda7c"
 [91] "eda12c"     "eda19c"     "hij5c"      "domestico"  "anios_esc"
 [96] "hrsocup"    "ingocup"    "ing_x_hrs"  "tpg_p8a"    "tcco"
[101] "cp_anoc"    "imssissste" "ma48me1sm"  "p14apoyos"  "scian"
[106] "t_tra"      "emp_ppal"   "tue_ppal"   "trans_ppal" "mh_fil2"
```

```
[111] "mh_col"     "sec_ins"    "tipo"       "mes_cal"
```

Más de otros *pipes* https://r4ds.had.co.nz/pipes.html

1.4 `select()` y `filter()`

Este es un recordatorio de que en `{dplyr}`, se filtran CASOS, es decir, líneas o renglones, y se seleccionan VARIABLES.

Por ejemplo:

```
  tlaxt322%>%
    dplyr::select(sex, eda) %>%
    dplyr::filter(eda>11)
```

```
# A tibble: 9,205 x 2
   sex          eda
   <dbl+lbl>  <dbl>
 1 1 [Hombre]    34
 2 2 [Mujer]     57
 3 1 [Hombre]    71
 4 1 [Hombre]    67
 5 2 [Mujer]     60
 6 2 [Mujer]     35
 7 1 [Hombre]    39
 8 1 [Hombre]    38
 9 2 [Mujer]     33
10 1 [Hombre]    14
# ... with 9,195 more rows
```

En la documentación de la base de datos de la ENOE se nos señala que debemos quedarnos con quienes tienen entrevista completa `r_def==0` y con quiénes son habitante habituales `(c_res!=2")`

Hagamos estos cambios:

```
  tlaxt322%<>%
    filter(r_def==0) %>%
    filter(!c_res==2)
```

1.5 Tabulados con `tabyl()`

El comando tabyl del paquete `{janitor}` nos sirve para hacer tabulados. Para que sean más bonitas, necesitaremos cambiar algunas de nuestras variables a sus datos etiquetados

```
tlaxt322%>%
  dplyr::mutate(sex=sjlabelled::as_label(sex))  %>%
  janitor::tabyl(sex)
```

```
   sex    n   percent
Hombre 5392 0.4767041
 Mujer 5919 0.5232959
```

Para ver que esto es una distribución de frecuencias sería muy útil ver la proporción total, ello se realiza agregando un elemento más en nuestro código con una "tubería":

```
tlaxt322%>%
  mutate(sex=as_label(sex)) %>%
  tabyl(sex) %>%
  adorn_totals() #primer enchulamiento
```

```
   sex     n   percent
Hombre  5392 0.4767041
 Mujer  5919 0.5232959
 Total 11311 1.0000000
```

Ahora, las proporciones son raras, y preferimos por los porcentajes.

```
tlaxt322%>%
  mutate(sex=as_label(sex)) %>% # cambia los valores de la variable a sus etiquetas
  tabyl(sex) %>% # para hacer la tabla
  adorn_totals() %>% # añade totales
  adorn_pct_formatting()  # nos da porcentaje en lugar de proporción
```

```
   sex     n percent
Hombre  5392   47.7%
 Mujer  5919   52.3%
 Total 11311  100.0%
```

Vamos a darle una "ojeada" a esta variable

```
glimpse(tlaxt322$niv_ins)
```

```
dbl+lbl [1:11311] 4, 2, 3, 3, 3, 4, 2, 3, 4, 2, 2, 2, 2, 3, 3, 2, 3, 2, 2,...
@ label       : chr "Clasificación de la población ocupada por nivel de instrucción"
@ format.stata: chr "%12.0g"
@ labels      : Named num [1:6] 0 1 2 3 4 5
 ..- attr(*, "names")= chr [1:6] "No aplica" "Primaria incompleta" "Prrimaria completa" "Se
```

Hoy hacemos la tabla, con las etiquetas:

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% #esto sólo si hay etiquetas declaradas, recuerda
  tabyl(niv_ins)
```

```
                niv_ins    n      percent
              No aplica  714 0.0631243922
     Primaria incompleta 2173 0.1921138715
      Prrimaria completa 2025 0.1790292635
     Secundaria completa 3201 0.2829988507
Medio superior y superior 3190 0.2820263460
         No especificado    8 0.0007072761
```

Para que no nos salgan las categorías sin datos podemos poner una opción dentro del comando “tabyl()”

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>%
  tabyl(niv_ins,
        show_missing_levels=F ) %>% # esta opción elimina los valores con 0
  adorn_totals()
```

```
                niv_ins     n      percent
              No aplica   714 0.0631243922
     Primaria incompleta  2173 0.1921138715
      Prrimaria completa  2025 0.1790292635
     Secundaria completa  3201 0.2829988507
Medio superior y superior  3190 0.2820263460
         No especificado     8 0.0007072761
                   Total 11311 1.0000000000
```

1.5.1 Cálculo de frecuencias

Las tablas de doble entrada tiene su nombre porque en las columnas entran los valores de una variable categórica, y en las filas de una segunda. Básicamente es como hacer un conteo de todas las combinaciones posibles entre los valores de una variable con la otra.

Por ejemplo, si quisiéramos combinar las dos variables que ya estudiamos lo podemos hacer, con una tabla de doble entrada:

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí
  adorn_totals()
```

```
                niv_ins Hombre Mujer
              No aplica    389   325
     Primaria incompleta   1066  1107
      Prrimaria completa    950  1075
     Secundaria completa   1450  1751
Medio superior y superior  1533  1657
         No especificado      4     4
                   Total   5392  5919
```

Observamos que en cada celda confluyen los casos que comparten las mismas características:

```
tlaxt322%>%
    count(niv_ins==1 & sex==1) # nos da la segunda celda de la izquierda
```

```
# A tibble: 2 x 2
  `niv_ins == 1 & sex == 1`     n
  <lgl>                     <int>
1 FALSE                     10245
2 TRUE                       1066
```

1.5.2 Totales y porcentajes

De esta manera se colocan todos los datos. Si observa al poner la función "adorn_totals()" lo agregó como una nueva fila de totales, pero también podemos pedirle que agregue una columna de totales.

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí sex
  adorn_totals("col")
```

```
                niv_ins Hombre Mujer Total
              No aplica    389   325   714
   Primaria incompleta   1066  1107  2173
    Prrimaria completa    950  1075  2025
   Secundaria completa   1450  1751  3201
Medio superior y superior   1533  1657  3190
        No especificado      4     4     8
```

O bien agregar los dos, introduciendo en el argumento `c("col", "row")` un vector de caracteres de las dos opciones requeridas:

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí sexo
  adorn_totals(c("col", "row"))
```

```
                niv_ins Hombre Mujer Total
              No aplica    389   325   714
   Primaria incompleta   1066  1107  2173
    Prrimaria completa    950  1075  2025
   Secundaria completa   1450  1751  3201
Medio superior y superior   1533  1657  3190
        No especificado      4     4     8
                  Total   5392  5919 11311
```

Del mismo modo, podemos calcular los porcentajes. Pero los podemos calcular de tres formas. Uno es que lo calculemos para los totales calculados para las filas, para las columnas o para el gran total poblacional.

Para columnas tenemos el siguiente código y los siguientes resultados:

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí sexo
  adorn_totals(c("col", "row")) %>%
```

```
  adorn_percentages("col") %>% # Divide los valores entre el total de la columna
  adorn_pct_formatting() # lo vuelve porcentaje
```

```
                niv_ins Hombre  Mujer  Total
              No aplica   7.2%   5.5%   6.3%
     Primaria incompleta  19.8%  18.7%  19.2%
      Prrimaria completa  17.6%  18.2%  17.9%
     Secundaria completa  26.9%  29.6%  28.3%
Medio superior y superior  28.4%  28.0%  28.2%
         No especificado   0.1%   0.1%   0.1%
                   Total 100.0% 100.0% 100.0%
```

Cuando se hagan cuadros de distribuciones (que todas sus partes suman 100), los porcentajes pueden ser una gran ayuda para la interpretación, sobre todos cuando se comparar poblaciones de categorías de diferente tamaño. Por lo general, queremos que los cuadros nos den información de donde están los totales y su 100%, de esta manera el lector se puede guiar de porcentaje con respecto a qué está leyendo. En este caso, vemos que el 100% es común en la última fila.

Veamos la diferencia de cómo podemos leer la misma celda, pero hoy, hemos calculado los porcentajes a nivel de fila:

```
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>%
  adorn_totals(c("col", "row")) %>%
  adorn_percentages("row") %>% # Divide los valores entre el total de la fila
  adorn_pct_formatting() # lo vuelve porcentaje
```

```
                niv_ins Hombre Mujer  Total
              No aplica  54.5% 45.5% 100.0%
     Primaria incompleta  49.1% 50.9% 100.0%
      Prrimaria completa  46.9% 53.1% 100.0%
     Secundaria completa  45.3% 54.7% 100.0%
Medio superior y superior  48.1% 51.9% 100.0%
         No especificado  50.0% 50.0% 100.0%
                   Total  47.7% 52.3% 100.0%
```

Finalmente, podemos calcular los porcentajes con referencia a la población total en análisis. Es decir la celda en la esquina inferior derecha de nuestra tabla original.

```r
tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí sexo
  adorn_totals(c("col", "row")) %>%
   adorn_percentages("all") %>% # Divide los valores entre el total de la población
  adorn_pct_formatting() # lo vuelve porcentaje
```

niv_ins	Hombre	Mujer	Total
No aplica	3.4%	2.9%	6.3%
Primaria incompleta	9.4%	9.8%	19.2%
Prrimaria completa	8.4%	9.5%	17.9%
Secundaria completa	12.8%	15.5%	28.3%
Medio superior y superior	13.6%	14.6%	28.2%
No especificado	0.0%	0.0%	0.1%
Total	47.7%	52.3%	100.0%

Chapter 2

Repaso de visualización de datos y {ggplot2}

2.1 Paquetes

```
if (!require("pacman")) install.packages("pacman")#instala pacman si se requiere
```

```
Loading required package: pacman
```

```
pacman::p_load(tidyverse,
               readxl,
               writexl,
               haven,
               sjlabelled,
               janitor,
               infer,
               ggpubr,
               magrittr,
               gt,
               GGally,
               broom,
               DescTools,
               wesanderson)
```

2.2 Cargando los datos

Desde STATA

```
tlaxt322 <- read_dta("./datos/tlaxt322.dta") %>%
  clean_names()
```

Desde Excel:

```
ICI_2021 <- read_excel("./datos/ICI_2021.xlsx",
                                sheet = "para_importar") %>%
  clean_names()
```

```
New names:
* `` -> `...2`
```

```
tlaxt322 %<>%
  filter(r_def==0) %>%
  filter(!c_res==2)
```

2.3 *Grammar of tables: gt*

Es un paquete que nos permite poner nuestras tablas en mejores formatos.

Guardemos un ejemplo anterior en un objeto

```
mi_tabla<-tlaxt322%>%
  mutate(niv_ins=as_label(niv_ins)) %>% # para que las lea como factor
  mutate(sex=as_label(sex)) %>% # para que las lea como factor
  tabyl(niv_ins, sex, show_missing_levels=F ) %>% # incluimos aquí sexo
  adorn_totals(c("col", "row")) %>%
   adorn_percentages("all") %>% # Divide los valores entre el total de la población
  adorn_pct_formatting() # lo vuelve porcentaje
```

Veamos qué pasa con el comando "gt"

```
gt_tabla<-gt(mi_tabla)
gt_tabla
```

niv_ins	Hombre	Mujer	Total

No aplica	3.4%	2.9%	6.3%
Primaria incompleta	9.4%	9.8%	19.2%
Prrimaria completa	8.4%	9.5%	17.9%
Secundaria completa	12.8%	15.5%	28.3%
Medio superior y superior	13.6%	14.6%	28.2%
No especificado	0.0%	0.0%	0.1%
Total	47.7%	52.3%	100.0%

Con este formato será bastante sencillo agregar títulos y demás:

```
gt_tabla<-gt_tabla %>%
  tab_header(
    title = "Distribución del sexo de la población según nivel de escolaridad",
    subtitle = "Tlaxcala, trimestre III de 2022"
  )

gt_tabla
```

Distribución del sexo de la población según nivel de escolaridad
Tlaxcala, trimestre III de 2022

niv_ins	Hombre	Mujer	Total
No aplica	3.4%	2.9%	6.3%
Primaria incompleta	9.4%	9.8%	19.2%
Prrimaria completa	8.4%	9.5%	17.9%
Secundaria completa	12.8%	15.5%	28.3%
Medio superior y superior	13.6%	14.6%	28.2%
No especificado	0.0%	0.0%	0.1%
Total	47.7%	52.3%	100.0%

Agreguemos la fuente a nuestra tabla:

```
gt_tabla<-gt_tabla %>%
  tab_source_note(
    source_note = "Fuente: Cálculos propios con datos de INEGI"
  )

gt_tabla
```

Distribución del sexo de la población según nivel de escolaridad
Tlaxcala, trimestre III de 2022

niv_ins	Hombre	Mujer	Total
No aplica	3.4%	2.9%	6.3%
Primaria incompleta	9.4%	9.8%	19.2%
Prrimaria completa	8.4%	9.5%	17.9%
Secundaria completa	12.8%	15.5%	28.3%
Medio superior y superior	13.6%	14.6%	28.2%
No especificado	0.0%	0.0%	0.1%
Total	47.7%	52.3%	100.0%

Fuente: Cálculos propios con datos de INEGI

Checa más de este paquete por aquí https://gt.rstudio.com/articles/intro-creating-gt-tables.html

2.4 Descriptivos para variables cuantitativas

Vamos a empezar a revisar los gráficos para variables cuantitativas.

2.4.1 Medidas numéricas básicas

5 números

```
summary(tlaxt322$ing_x_hrs) ## ingreso por horas
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   0.00    0.00    0.00   12.10   18.75 1356.59
```

Con pipes se pueden crear "indicadores" de nuestras variables es un tibble

```
tlaxt322%>%
  summarise(nombre_indicador=mean(ing_x_hrs, na.rm=T))
```

```
# A tibble: 1 x 1
  nombre_indicador
             <dbl>
1             12.1
```

2.5 Visualización de datos, un pequeño disclaimer

Hay cursos específicos de visualización de datos. Es maravilloso pero también requiere que estudiemos bien qué tipo de datos tenemos y cuáles son nuestros objetivos.

Me gusta mucho este recurso: https://www.data-to-viz.com/

2.5.1 Gráficos de base

"plot()" Es la función más simple.

```
plot(as_label(tlaxt322$niv_ins))
```

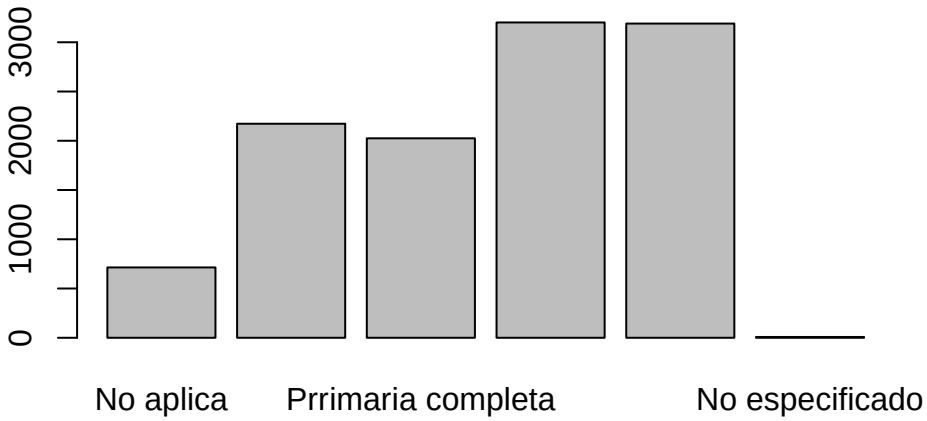

Esto es igual que:

```
barplot(table(as_label(tlaxt322$niv_ins)))
```

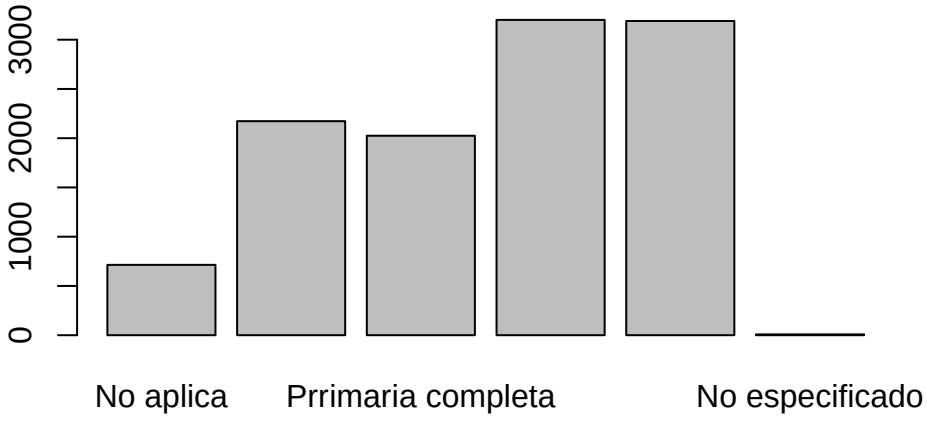

Histograma y el boxplot

```
hist(ICI_2021$esperanza_de_vida)
```

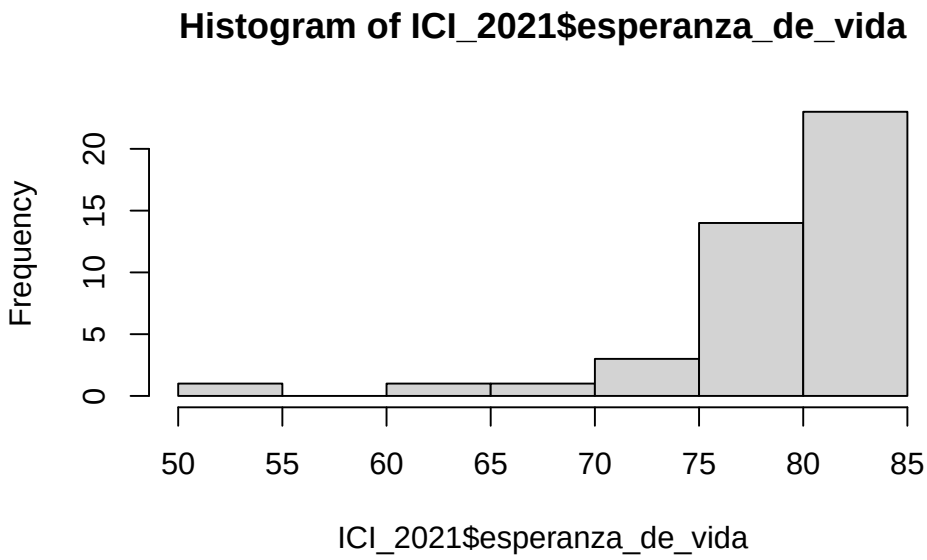


```
boxplot(ICI_2021$esperanza_de_vida)
```

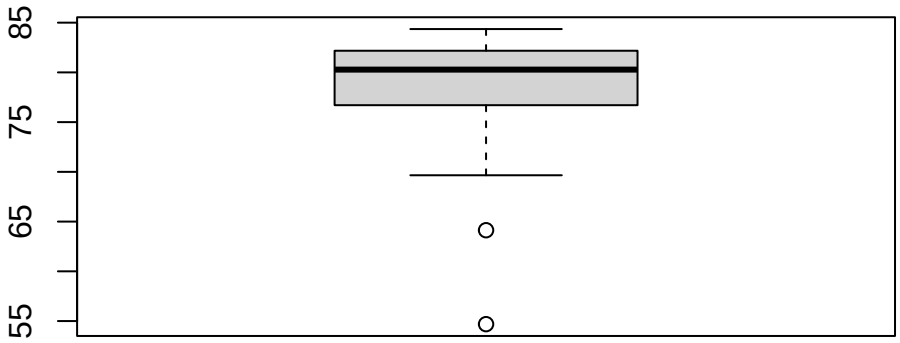

2.6 *Grammar of graphics: ggplot*

Hoy vamos a presentar a un gran paquete ¡Es de los famosos! Y tiene más de diez años.

- https://qz.com/1007328/all-hail-ggplot2-the-code-powering-all-those-excellent-charts-is-10-years-old/

"gg" proviene de "Grammar of Graphics", funciona un poco como sintácticamente, de ahí su nombre.

Algunos recursos para aprender ggplot

- https://ggplot2-book.org/ hecha por el mero mero.
- http://sape.inf.usi.ch/quick-reference/ggplot2
- https://raw.githubusercontent.com/rstudio/cheatsheets/master/data-visualization-2.1.pdf

Vamos a revisar una presentación que es muy interesante

- https://evamaerey.github.io/ggplot2_grammar_guide/ggplot2_grammar_guide.html
- https://huygens.science.uva.nl/ggPlotteR/ Hace gráficos de ggplot con la base de datos de Gapminder

2.6.1 Un lienzo para dibujar

Para hacer un gráfico, ggplot2 tiene el comando "ggplot()". Hacer gráficos con esta función tiene una lógica aditiva. Lo ideal es que iniciemos estableciendo el mapeo estético de nuestro gráfico, con el comando aes()

```r
g1<-tlaxt322 %>%
  ggplot(aes(as_label(niv_ins)))

g1 ## imprime el lienzo
```

2.6.2 Gráficos univariados

2.6.2.1 Para cualitativas

```r
g1 + geom_bar()
```

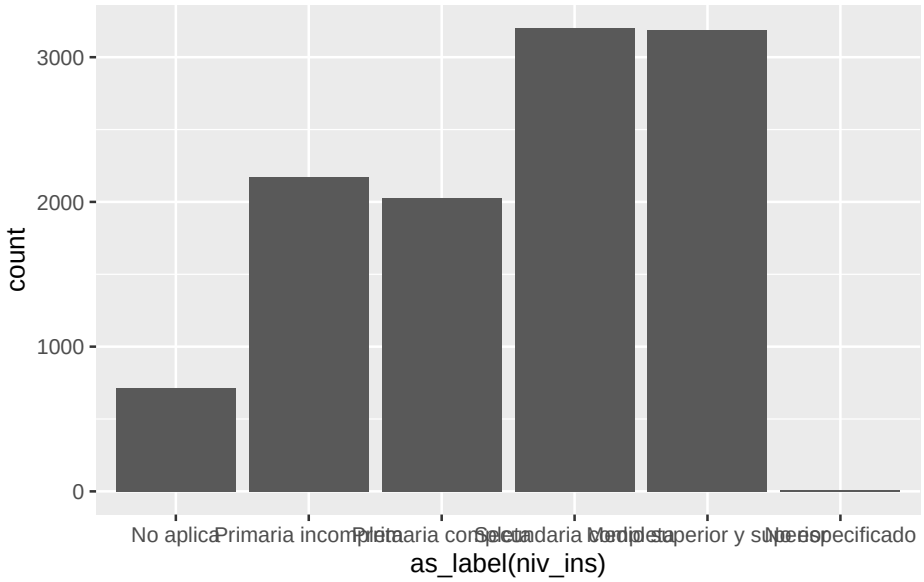


```
g1 +  geom_bar(aes(
  fill = as_label(niv_ins)
  )) ## colorea la geometría
```

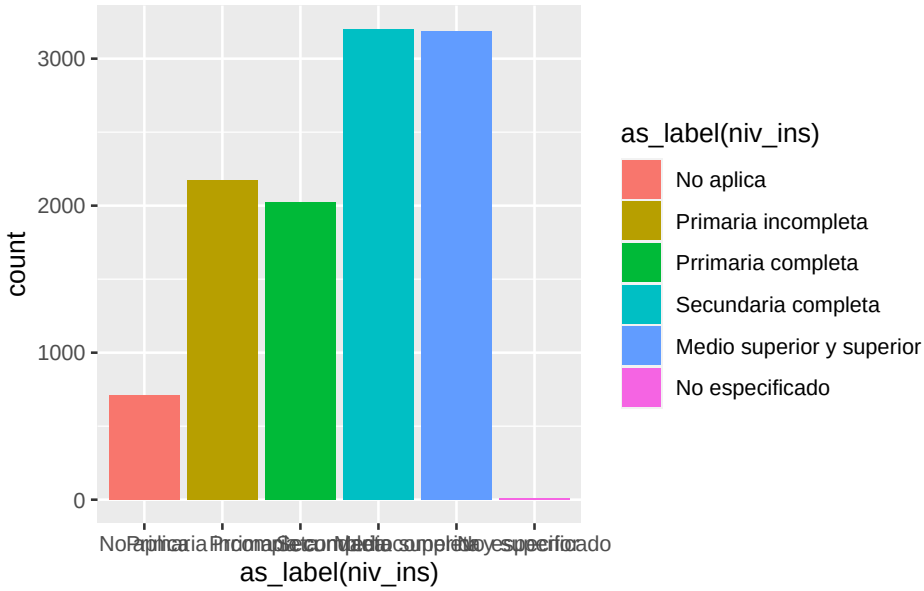

```
## Esto es equivalente

tlaxt322 %>%
  ggplot(aes(as_label(niv_ins),
             fill = as_label(niv_ins)
             )
         ) + geom_bar()
```

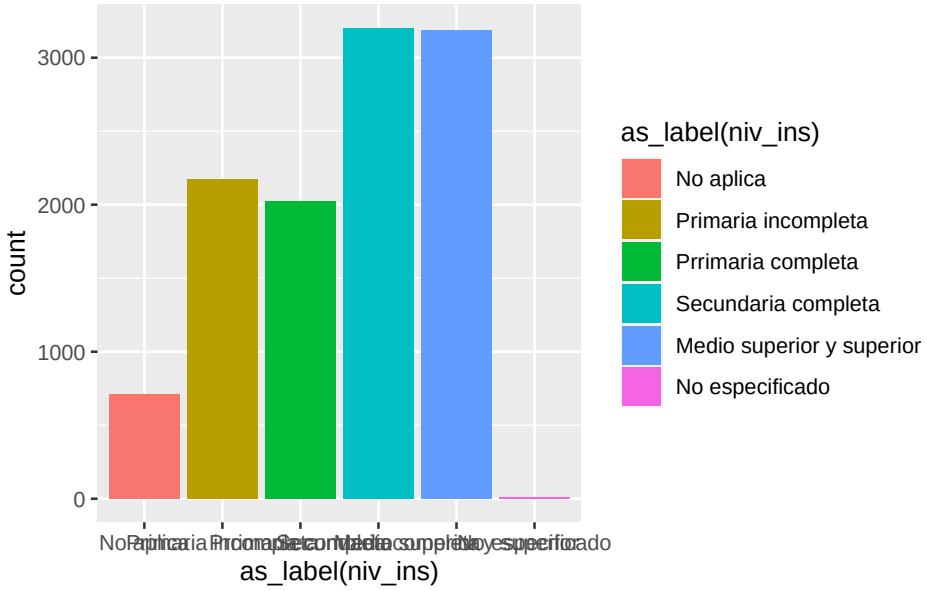

2.6.2.2 Para variables cuantitativas

Podemos hacer histogramas y gráficos de densidad, de manera fácil. La idea es agregar en nuestro "lienzo" una geometría, un valor para dibujar en él. Esto se agrega con un "+" y con la figura que se añadirá a nuestro gráfico.

```
g2<-tlaxt322 %>%
  ggplot(aes(eda))

g2 ## imprime el lienzo
```

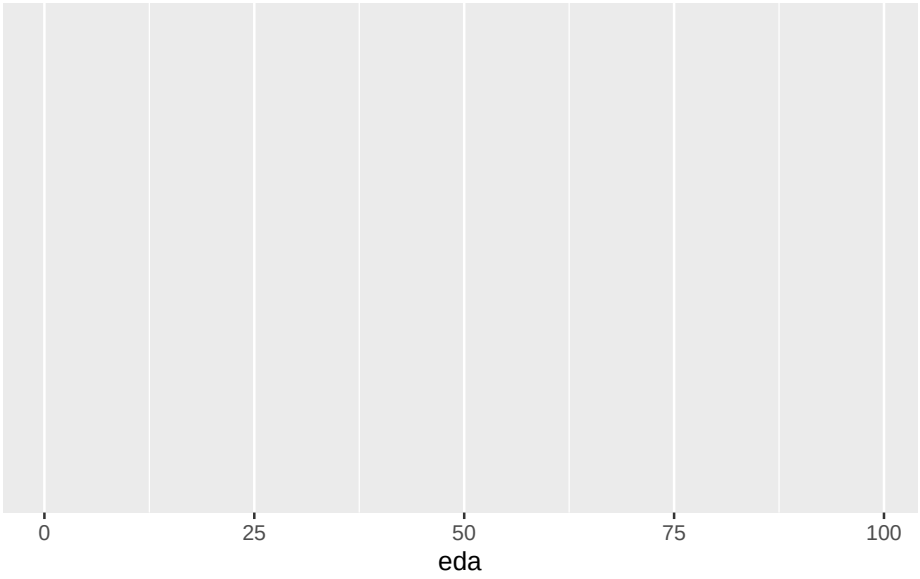

2.6.2.2.1 Histograma

```
g2 + geom_histogram()
```

```
`stat_bin()` using `bins = 30`. Pick better value with `binwidth`.
```

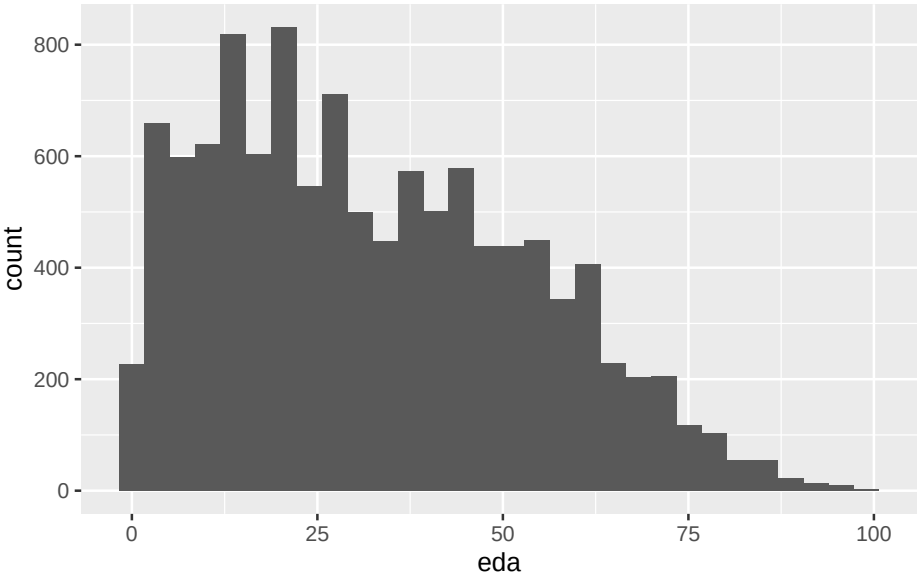

2.6.2.2.2 Densidad

```
g2 + geom_density()
```

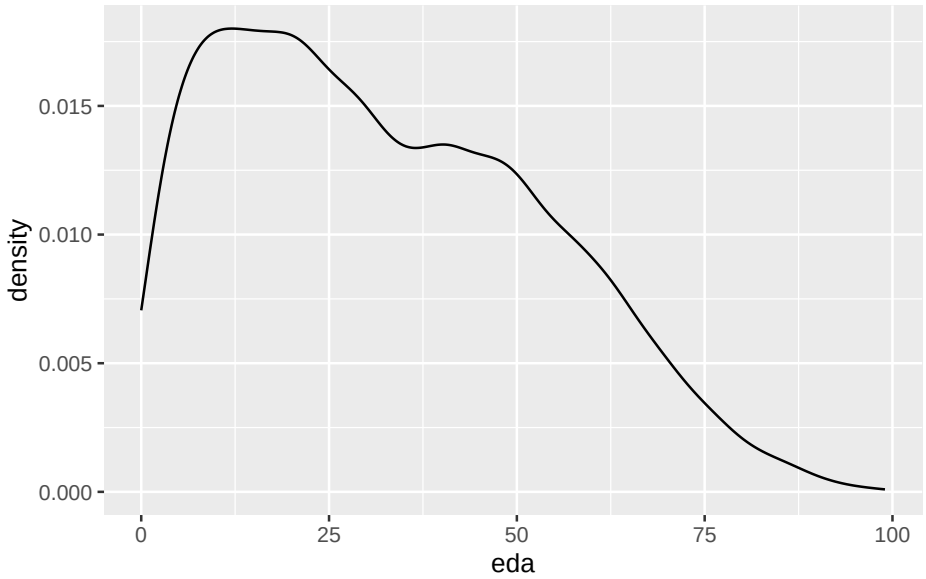

2.7 Intro a dos variables

Para hacer un lienzo con dos variables:

```
tlaxt322 %>%
  filter(ing_x_hrs>0) %>%
  filter(anios_esc<99) %>%  #
  ggplot()+
  aes(x = anios_esc,
      y = ing_x_hrs)
```

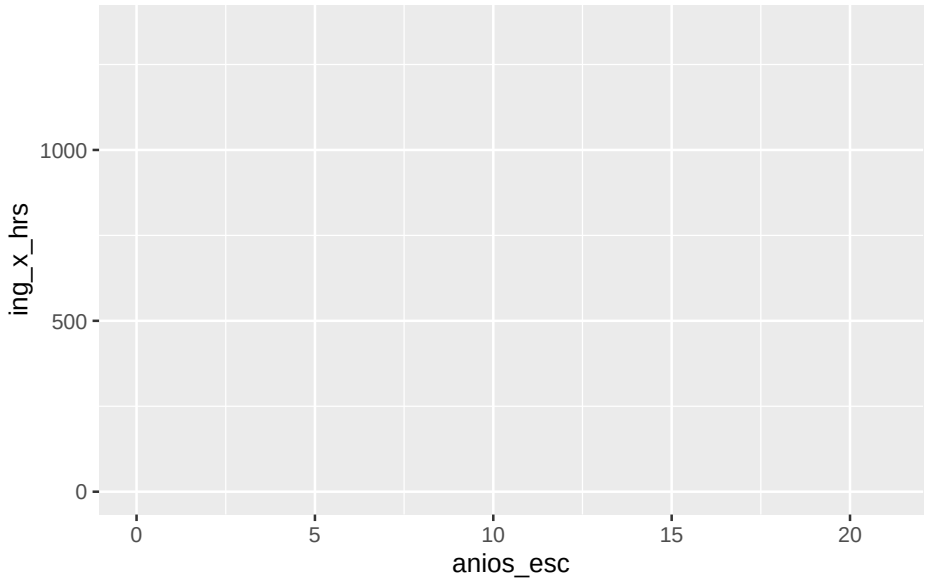

Con esto podemos agregar la geometría de puntito:

```
tlaxt322 %>%
  filter(ing_x_hrs>0) %>%
  filter(anios_esc<99) %>%  #
  ggplot()+
  aes(x = anios_esc,
      y = ing_x_hrs) +
  geom_point()
```

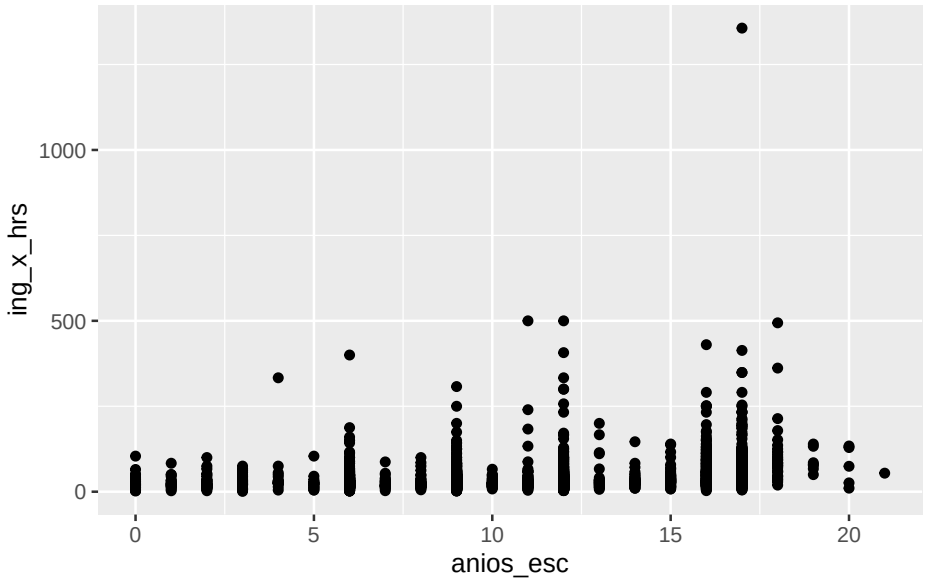

Vamos a terminar con un código que resume mucho de lo que hemos visto hoy:

```
tlaxt322 %>%
  filter(clase2==1) %>%  ## nos quedamos sólo con los ocupados
  select(eda, ing_x_hrs, anios_esc) %>%
  GGally::ggpairs()
```

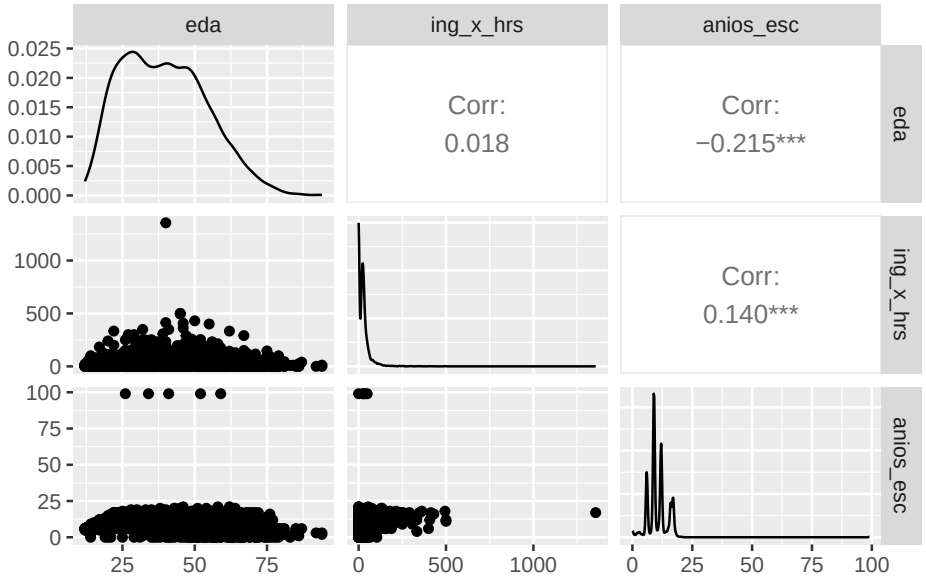

Chapter 3

Introducción a la inferencia

3.1 Paquetes

```
if (!require("pacman")) install.packages("pacman")#instala pacman si se requiere
```

```
Loading required package: pacman
```

```
pacman::p_load(tidyverse,
               readxl,
               writexl,
               haven,
               sjlabelled,
               janitor,
               infer,
               ggpubr,
               magrittr,
               gt,
               GGally,
               broom,
               DescTools,
               wesanderson,
               gtsummary,
               srvyr,
               car)
```

3.2 Cargando los datos

Desde STATA

```
tlaxt322 <- read_dta("./datos/tlaxt322.dta") %>%
  clean_names() %>%
  filter(r_def==0) %>%
  filter(!c_res==2)
```

Desde Excel:

```
ICI_2021 <- read_excel("./datos/ICI_2021.xlsx",
                                  sheet = "para_importar") %>%
  clean_names()
```

```
New names:
* `` -> `...2`
```

3.3 Hipótesis e intervalos de confianza

3.3.1 t-test

Este comando nos sirve para calcular diferentes tipos de test, que tienen como base la distribución t

Univariado para estimación

```
t.test(tlaxt322$ing_x_hrs) # pero no tenemos los filtro
```

```

    One Sample t-test

data:  tlaxt322$ing_x_hrs
t = 42.362, df = 11310, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 11.53964 12.65937
sample estimates:
mean of x
 12.09951
```

Un truco para poder utilizar funciones de base con formato *tidy*

```r
tlaxt322 %>%
  filter(clase2==1) %>% #Filtro de ocupados
  filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
  with(
    t.test(ing_x_hrs)
  )
```

```
    One Sample t-test

data:  ing_x_hrs
t = 51.961, df = 3631, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 36.25925 39.10282
sample estimates:
mean of x
 37.68103
```

Vamos a quedarnos a con esta población objetivo:

Univariado para hipótesis específica

$$H_o : \mu = 40$$
$$H_{a1} : \mu < 40$$
$$H_{a2} : \mu \neq 40$$
$$H_{a3} : \mu > 40$$

Si hacemos explícita la H_0

```r
tlaxt322 %>%
  filter(clase2==1) %>% #Filtro de ocupados
  filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
  with(
    t.test(ing_x_hrs, mu=40)
    )
```

```
    One Sample t-test

data:  ing_x_hrs
t = -3.1978, df = 3631, p-value = 0.001397
```

```
alternative hypothesis: true mean is not equal to 40
95 percent confidence interval:
 36.25925 39.10282
sample estimates:
mean of x
 37.68103
```

Para hacer explícitas las hipótesis alternativas

```
  tlaxt322 %>%
    filter(clase2==1) %>% #Filtro de ocupados
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    with(
    t.test(ing_x_hrs, mu=40, alternative = "two.sided") #default y de dos colas
      )
```

```
    One Sample t-test

data:  ing_x_hrs
t = -3.1978, df = 3631, p-value = 0.001397
alternative hypothesis: true mean is not equal to 40
95 percent confidence interval:
 36.25925 39.10282
sample estimates:
mean of x
 37.68103
```

```
  tlaxt322 %>%
    filter(clase2==1) %>% #Filtro de ocupados
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    with(
    t.test(ing_x_hrs, mu=40, alternative = "greater") # cola derecha
      )
```

```
    One Sample t-test

data:  ing_x_hrs
t = -3.1978, df = 3631, p-value = 0.9993
alternative hypothesis: true mean is greater than 40
95 percent confidence interval:
 36.48793      Inf
```

```
sample estimates:
mean of x
 37.68103
```

```
  tlaxt322 %>%
    filter(clase2==1) %>% #Filtro de ocupados
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    with(
    t.test(ing_x_hrs, mu=40, alternative = "less") # cola izquierda
      )
```

```
    One Sample t-test

data:  ing_x_hrs
t = -3.1978, df = 3631, p-value = 0.0006983
alternative hypothesis: true mean is less than 40
95 percent confidence interval:
     -Inf 38.87414
sample estimates:
mean of x
 37.68103
```

3.3.2 Enchulando un poquito

Los resultados tienen la info, pero la podemos almacenar en un objeto. Con los cálculos de modelos es muy útil guardarlos para compararlos.

```
  t.test0<-tlaxt322 %>%
    filter(clase2==1) %>% #Filtro de ocupados
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    with(
      t.test(ing_x_hrs, mu=40)
      )
```

Veamos si lo imprimimos

```
  t.test0
```

```
    One Sample t-test

data:  ing_x_hrs
```

```
t = -3.1978, df = 3631, p-value = 0.001397
alternative hypothesis: true mean is not equal to 40
95 percent confidence interval:
 36.25925 39.10282
sample estimates:
mean of x
 37.68103
```

```
broom::tidy(t.test0)
```

```
# A tibble: 1 x 8
  estimate statistic p.value parameter conf.low conf.high method         alter~1
     <dbl>     <dbl>   <dbl>     <dbl>    <dbl>     <dbl> <chr>          <chr>
1     37.7     -3.20 0.00140      3631     36.3      39.1 One Sample t-~ two.si~
# ... with abbreviated variable name 1: alternative
```

La función `tidy()` hace que el resultado se vuelva un `tibble`, una tabla muy compatible con el tidyverse. Esto puede ser útil cuando queremos ir comparando estimaciones.

Anteriormente vimos con base cómo hacer inferencia. El paquete `{infer}` tiene también elementos para inferencia, pero en formato más compatible con tidyverse.

```
tlaxt322 %>%
  filter(clase2==1) %>% #Filtro de ocupados
  filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
  infer::t_test(response = ing_x_hrs, mu = 40)
```

```
# A tibble: 1 x 7
  statistic  t_df p_value alternative estimate lower_ci upper_ci
      <dbl> <dbl>   <dbl> <chr>          <dbl>    <dbl>    <dbl>
1     -3.20  3631 0.00140 two.sided       37.7     36.3     39.1
```

Como vemos nos da el mismo resultado anterior, pero nos da directamente el resultado en formato tidy.

Si solo queremos el estimador de "t"

```
tlaxt322 %>%
t_stat(response = ing_x_hrs, mu = 40)
```

```
Warning: The t_stat() wrapper has been deprecated in favor of the more general
observe(). Please use that function instead.
```

```
        t
-97.68389
```

Más de este paquete https://infer.netlify.app/

3.3.3 Prueba para proporción

Vamos a revisar la proporción de hombres y mujeres en términos de participación laboral.

El comando de base es menos flexible:

```
prop<-table(tlaxt322[tlaxt322$clase1>0,]$clase1)
prop.test(prop)
```

```
    1-sample proportions test with continuity correction

data:  prop, null probability 0.5
X-squared = 259.77, df = 1, p-value < 2.2e-16
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.5739084 0.5941550
sample estimates:
        p
0.5840669
```

Los filtros se complican un poco...

```
tlaxt322 %>%
  filter(eda>14 & eda<99) %>%
  mutate(clase1=as_label(clase1)) %>% #oo
  tabyl(clase1)
```

```
                          clase1    n   percent
                       No aplica    0 0.0000000
   Población económicamente activa 5326 0.6208183
Población no económicamente activa 3253 0.3791817
```

Vamos a aprovechar para re-etiquetar la variable clase1

```
etiqueta_pea<-c("PEA", "PNEA") # un vector con las etiquetas
```

```
tlaxt322 %>%
  filter(eda>14 & eda<99) %>%
  sjlabelled::set_labels(clase1, labels=etiqueta_pea) %>%
  mutate(clase1=as_label(clase1)) %>%
  tabyl(clase1)
```

```
 clase1    n   percent
    PEA 5326 0.6208183
   PNEA 3253 0.3791817
```

En formato tidy

```
tlaxt322 %>%
  filter(eda>14 & eda<99) %>%
  with(
    table(clase1)
    ) %>%
  prop.test()
```

```
    1-sample proportions test with continuity correction

data:  ., null probability 0.5
X-squared = 500.43, df = 1, p-value < 2.2e-16
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.6104410 0.6310868
sample estimates:
        p
0.6208183
```

En base necesita que se alimente de un objeto tipo table, el cual es menos manejable. Por eso utilizaremos más el paquete `{infer}`

```
tlaxt322 %>%
  filter(eda>14 & eda<99) %>%
  set_labels(clase1, labels=etiqueta_pea) %>%
  mutate(clase1=as_label(clase1)) %>%
  infer::prop_test(clase1 ~ NULL  ,
              p=0.7,
             alternative="less")
```

```
# A tibble: 1 x 4
  statistic chisq_df  p_value alternative
      <dbl>    <int>    <dbl> <chr>
1      256.        1 7.22e-58 less
```

```
# Para que nos dé Z
tlaxt322 %>%
  filter(eda>14 & eda<99) %>%
  set_labels(clase1, labels=etiqueta_pea) %>%
  mutate(clase1=as_label(clase1)) %>%
  infer::prop_test(clase1 ~ NULL  ,
            p=0.7,
            alternative="less",
            success = "PEA", # necesitamos establecer el éxito
            z=TRUE)
```

```
# A tibble: 1 x 3
  statistic  p_value alternative
      <dbl>    <dbl> <chr>
1     -16.0 5.97e-58 less
```

3.4 Estimaciones bivariadas

3.4.1 Diferencias de medias por grupos

¿Podemos decir, con significancia estadística que los valores medios de una variable son diferentes entre los grupos?

```
tlaxt322%>%
    filter(clase2==1) %>% # nos quedamos con los trabajadores
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    group_by(as_label(sex)) %>%
    summarise(avg_hrs = mean(ing_x_hrs, na.rm=T))
```

```
# A tibble: 2 x 2
  `as_label(sex)` avg_hrs
  <fct>             <dbl>
1 Hombre             39.0
2 Mujer              35.8
```

```
tlaxt322%>%
    filter(clase2==1) %>% # nos quedamos con los trabajadores
    filter(ing_x_hrs>0) %>% #Filtros de quienes reportaron ingresos
    with(
      t.test(ing_x_hrs~sex)
      )
```

```
    Welch Two Sample t-test

data:  ing_x_hrs by sex
t = 2.2679, df = 3598.8, p-value = 0.0234
alternative hypothesis: true difference in means between group 1 and group 2 is not equal to
95 percent confidence interval:
 0.4312905 5.9358857
sample estimates:
mean in group 1 mean in group 2
       38.98269        35.79911
```

Con "infer" sería:

```
tlaxt322%>%
  mutate(sex=as_label(sex)) %>%
  infer::t_test(ing_x_hrs ~ sex, order = c("Hombre", "Mujer") )
```

```
# A tibble: 1 x 7
  statistic  t_df  p_value alternative estimate lower_ci upper_ci
      <dbl> <dbl>    <dbl> <chr>          <dbl>    <dbl>    <dbl>
1      11.3 9280. 2.02e-29 two.sided       6.54     5.41     7.68
```

3.4.2 Diferencias de proporciones.

En la versión tidy de infer será más fácil hacer la versión de dos proporciones.

```
tlaxt322%>%
  filter(eda>14 & eda<99) %>%
  set_labels(clase1, labels=etiqueta_pea) %>%
  mutate(clase1=as_label(clase1)) %>%
  mutate(sex=as_label(sex)) %>%
  infer::prop_test(clase1 ~ sex ,
                   alternative="greater",
                   success = "PEA", # necesitamos establecer el éxito
```

```
                    order = c("Hombre", "Mujer"),
                    z=TRUE)
```

```
# A tibble: 1 x 5
  statistic   p_value alternative lower_ci upper_ci
      <dbl>     <dbl> <chr>          <dbl>    <dbl>
1      29.8 7.30e-195 greater        0.313        1
```

Chapter 4

Introducción a la inferencia (II)

4.1 Paquetes

```
if (!require("pacman")) install.packages("pacman")#instala pacman si se requiere
```

```
Loading required package: pacman
```

```
pacman::p_load(tidyverse,
               readxl,
               writexl,
               haven,
               sjlabelled,
               janitor,
               infer,
               ggpubr,
               magrittr,
               gt,
               GGally,
               broom,
               DescTools,
               wesanderson,
               gtsummary,
               srvyr,
               car)
```

4.2 Cargando los datos

Desde STATA

```
tlaxt322 <- read_dta("./datos/tlaxt322.dta") %>%
  clean_names() %>%
  filter(r_def==0) %>%
  filter(!c_res==2)
```

Desde Excel:

```
ICI_2021 <- read_excel("./datos/ICI_2021.xlsx",
                                  sheet = "para_importar") %>%
  clean_names()
```

```
New names:
* `` -> `...2`
```

4.3 Factores de expansión y diseño muestral

4.3.1 La función tally

El comando `tabyl()` del paquete `{janitor}` es muy útil pero no es compatible con los factores del expansión. En realidad, `tabyl()` nos ahorra un poco el hecho de tener que agrupar nuestra base en categorías y luego hacer un conteo para cada una de ellas. `tally()` es un comando que nos hace ese conteo y `group_by()` nos agrupa las observaciones de nuestra base de datos para hacer cualquier operación.

```
tlaxt322  %>%
 group_by(as_label(sex)) %>%
  tally(fac_tri) %>% #nombre del factor
  adorn_totals()  # Agrega total
```

```
as_label(sex)       n
       Hombre  650712
        Mujer  720359
        Total 1371071
```

Podemos usar funciones de `adorn_...` de `{janitor}`

```r
tlaxt322  %>%
 group_by(as_label(sex)) %>%
  tally(fac_tri) %>% #nombre del factor
  adorn_totals() %>% # Agrega total
  adorn_percentages("all")  %>%
  adorn_pct_formatting()
```

```
as_label(sex)      n
       Hombre  47.5%
        Mujer  52.5%
        Total 100.0%
```

4.3.2 Otras formas

La función `count()` también permite dar pesos

```r
tlaxt322  %>%
  dplyr::count(sex, niv_ins,  wt = fac_tri)
```

```
# A tibble: 12 x 3
   sex        niv_ins                           n
   <dbl+lbl>  <dbl+lbl>                     <dbl>
 1 1 [Hombre] 0 [No aplica]                47513
 2 1 [Hombre] 1 [Primaria incompleta]      130266
 3 1 [Hombre] 2 [Prrimaria completa]       116761
 4 1 [Hombre] 3 [Secundaria completa]      178274
 5 1 [Hombre] 4 [Medio superior y superior] 177459
 6 1 [Hombre] 5 [No especificado]            439
 7 2 [Mujer]  0 [No aplica]                40662
 8 2 [Mujer]  1 [Primaria incompleta]      137557
 9 2 [Mujer]  2 [Prrimaria completa]       132531
10 2 [Mujer]  3 [Secundaria completa]      213295
11 2 [Mujer]  4 [Medio superior y superior] 195934
12 2 [Mujer]  5 [No especificado]            380
```

Es compatible con etiquetas

```r
tlaxt322  %>%
  count(as_label(sex), as_label(niv_ins),  wt = fac_tri)
```

```
# A tibble: 12 x 3
```

```
   `as_label(sex)` `as_label(niv_ins)`            n
   <fct>           <fct>                      <dbl>
 1 Hombre          No aplica                  47513
 2 Hombre          Primaria incompleta       130266
 3 Hombre          Prrimaria completa        116761
 4 Hombre          Secundaria completa       178274
 5 Hombre          Medio superior y superior 177459
 6 Hombre          No especificado              439
 7 Mujer           No aplica                  40662
 8 Mujer           Primaria incompleta       137557
 9 Mujer           Prrimaria completa        132531
10 Mujer           Secundaria completa       213295
11 Mujer           Medio superior y superior 195934
12 Mujer           No especificado              380
```

Podemos mover un poquito con pivot_wider para que se vea más a lo que acostumbramos a una tabla de frecuencias

```
tlaxt322  %>%
  mutate_at(vars(sex, niv_ins), as_label) %>%
  count(sex, niv_ins,  wt = fac_tri) %>%
  tidyr::pivot_wider(names_from = sex,
              values_from = n)
```

```
# A tibble: 6 x 3
  niv_ins                   Hombre  Mujer
  <fct>                      <dbl>  <dbl>
1 No aplica                  47513  40662
2 Primaria incompleta       130266 137557
3 Prrimaria completa        116761 132531
4 Secundaria completa       178274 213295
5 Medio superior y superior 177459 195934
6 No especificado              439    380
```

```
tlaxt322  %>%
  mutate_at(vars(sex, niv_ins), as_label) %>% # otra forma de mutate y as_label
  count(sex, niv_ins,  wt = fac_tri) %>%
  pivot_wider(names_from = sex,
              values_from = n) %>%
  adorn_totals() %>% # Agrega total
  adorn_percentages("col")  %>%
  adorn_pct_formatting()
```

```
                  niv_ins Hombre  Mujer
                No aplica   7.3%   5.6%
      Primaria incompleta  20.0%  19.1%
       Prrimaria completa  17.9%  18.4%
      Secundaria completa  27.4%  29.6%
Medio superior y superior  27.3%  27.2%
          No especificado   0.1%   0.1%
                    Total 100.0% 100.0%
```

4.3.3 Diseño complejo

Hay muchos diseños muestrales, asumiremos el diseño simple, pero hay que revisar la documentación de la base

```
# Muestreo aleatorio
tlax_srvy <- tlaxt322  %>%
  as_survey_design(weights = fac_tri)
```

Si revisamos las encuestas tiene un diseño complejo, hay estratos y unidades primarias de muestreo

```
# Muestreo estratificado
tlax_srvy <- tlaxt322  %>%
  as_survey_design(
    upm,
    strata = est_d_tri,
    weights = fac_tri,
    nest = TRUE)
```

Como vemos esto es un archivo bien grande, por lo que mejor vamos a seleccionar un par de variables:

```
# simple random sample
tlax_srvy <- tlaxt322  %>%
  select(upm,est_d_tri, fac_tri, starts_with("clase"),
         sex, eda, anios_esc, ing_x_hrs, fac_tri) %>%
  as_survey_design(
    upm,
    strata = est_d_tri,
    weights = fac_tri,
    nest = TRUE)
```

Para una media ponderada

```
tlax_srvy %>%
  filter(eda>14 & eda<99) %>% #filtro de edad para tabulados
  filter(clase2==1) %>% # sólo ocupados
  filter(ing_x_hrs>0) %>% # sólo con ingresos
  summarise(
    media_ponderada = survey_mean(ing_x_hrs, na.rm=T))
```

```
# A tibble: 1 x 2
  media_ponderada media_ponderada_se
            <dbl>               <dbl>
1            37.1               0.818
```

Este valor coincide con los datos publicados por INEGI, incluso el error estándar. Si queremos los intervalos de confianza:

```
tlax_srvy %>%
  filter(eda>14 & eda<99) %>% #filtro de edad para tabulados
  filter(clase2==1) %>% # sólo ocupados
  filter(ing_x_hrs>0) %>% # sólo con ingresos
  summarize(
    media_ponderada = survey_mean(ing_x_hrs,
                                  vartype = "ci") )
```

```
# A tibble: 1 x 3
  media_ponderada media_ponderada_low media_ponderada_upp
            <dbl>                <dbl>                <dbl>
1            37.1                 35.5                 38.7
```

```
tlax_srvy %>%
  filter(eda>14 & eda<99) %>% #filtro de edad para tabulados
  filter(clase2==1) %>% # sólo ocupados
  filter(ing_x_hrs>0) %>% # sólo con ingresos
  summarize(
    mediana_ponderada = survey_median(ing_x_hrs,
                                  vartype = "ci") )
```

```
# A tibble: 1 x 3
  mediana_ponderada mediana_ponderada_low mediana_ponderada_upp
              <dbl>                 <dbl>                 <dbl>
1              27.1                  26.7                    28
```

```
  tlax_srvy %>%
    mutate(sex=as_label(sex)) %>%
    group_by(sex) %>% #variables cuali
    summarize(proportion = survey_mean(), # proporción
              total = survey_total() ) # totales
```

```
# A tibble: 2 x 5
  sex    proportion proportion_se  total total_se
  <fct>       <dbl>         <dbl>  <dbl>    <dbl>
1 Hombre      0.475       0.00397 650712   12123.
2 Mujer       0.525       0.00397 720359   12890.
```

4.4 Estimación de varianzas y sus pruebas de hipótesis

Para poder hacer inferencia sobre la varianza utilizamos el comando `varTest()` del paquete `{DescTools}`

```
  tlaxt322%>%
      filter(ing_x_hrs>0) %>%
        with(
          DescTools::VarTest(ing_x_hrs)
          )
```

```
    One Sample Chi-Square test on variance

data:  ing_x_hrs
X-squared = 6935154, df = 3631, p-value < 2.2e-16
alternative hypothesis: true variance is not equal to 1
95 percent confidence interval:
 1825.084 2000.980
sample estimates:
variance of x
     1909.984
```

Podemos también decir algo sobre el valor objetivo de nuestra hipótesis

```
  tlaxt322%>%
      filter(ing_x_hrs>0) %>%
        with(
```

```
        VarTest(ing_x_hrs, sigma.squared = 100)
        )
```

```
    One Sample Chi-Square test on variance

data:  ing_x_hrs
X-squared = 69352, df = 3631, p-value < 2.2e-16
alternative hypothesis: true variance is not equal to 100
95 percent confidence interval:
 1825.084 2000.980
sample estimates:
variance of x
     1909.984
```

$$H_o : \sigma = 100$$

4.5 Análisis de varianza

Análisis de varianza. Haremos la versión más simple. Para ver el efecto de un factor sobre una variable cualitativa (oneway). Revisaremos si la región de residencia de los trabajadores tiene un efecto en la distribución de los ingresos por trabajo.

4.5.1 Primero un gráfico

la ANOVA se basa en que nuestra variable es normal. Quitaremos los outliers

```
lienzo_bi <-tlaxt322  %>%
           filter(clase2==1  & !ing_x_hrs==0) %>%
           ggplot(aes(x=log(ing_x_hrs), fill=as_factor(t_loc_tri),
           color=as_factor(t_loc_tri),
           alpha=I(0.5)))

lienzo_bi + geom_density()
```

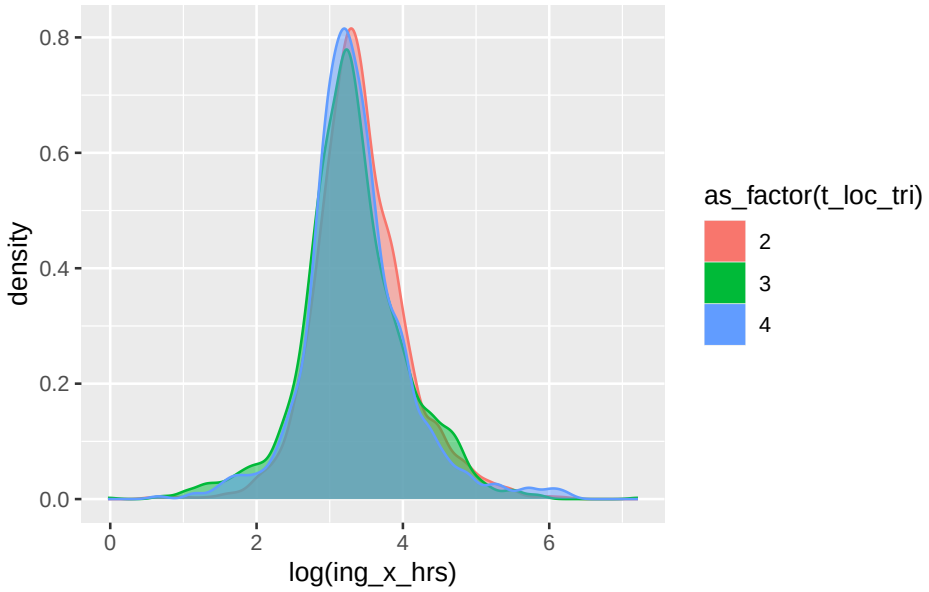

La prueba ANOVA o análisis de varianza, nos dice cuánto de nuestra variable se ve explicado por un factor.

$$H_o : \mu_1 = \mu_2 = \mu_3 = \mu_4$$

$$H_a : \text{Alguna de las medias es diferente}$$

En los modelos es mul útil guardar nuestros resultados como un objeto

```
anova<-tlaxt322  %>%
    filter(ing_x_hrs>0) %>%
      with(
        aov(log(ing_x_hrs) ~ as_factor(t_loc_tri))
           )

summary(anova)
```

```
                      Df Sum Sq Mean Sq F value   Pr(>F)
as_factor(t_loc_tri)    2    7.9   3.963   8.559 0.000196 ***
Residuals            3629 1680.1   0.463
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Con tidy:

```r
tidy(anova)
```

```
# A tibble: 2 x 6
  term                   df   sumsq meansq statistic   p.value
  <chr>                <dbl>   <dbl>  <dbl>     <dbl>     <dbl>
1 as_factor(t_loc_tri)     2    7.93  3.96       8.56  0.000196
2 Residuals             3629 1680.    0.463     NA    NA
```

4.5.2 Comparación entre grupos

¿si es significativo cuáles diferencias entre los grupos lo son?

```r
TukeyHSD(anova)
```

```
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = log(ing_x_hrs) ~ as_factor(t_loc_tri))

$`as_factor(t_loc_tri)`
           diff         lwr           upr     p adj
3-2 -0.10293620 -0.16198416 -0.0438882377 0.0001319
4-2 -0.07426595 -0.14892702  0.0003951272 0.0515889
4-3  0.02867025 -0.04398701  0.1013275135 0.6243629
```

4.5.3 Supuestos de ANOVA

- Las observaciones se obtienen de forma independiente y aleatoria de la población definida por los niveles del factor
- Los datos de cada nivel de factor se distribuyen normalmente.
- Estas poblaciones normales tienen una varianza común.

```r
#Prueba Bartlett para ver si las varianzas son iguales

tlaxt322  %>%
    filter(clase2==1) %>%
      with(bartlett.test(ing_x_hrs ~ as_factor(t_loc_tri)))
```

```
    Bartlett test of homogeneity of variances
```

```
data:  ing_x_hrs by as_factor(t_loc_tri)
Bartlett's K-squared = 132, df = 2, p-value < 2.2e-16
```

La prueba tiene una Ho "Las varianzas son iguales"

```
#Test Normalidad
tlaxt322  %>%
  filter(clase2==1) %>%
  filter(ing_x_hrs>0) %>%
 with(
    ks.test(log(ing_x_hrs),
            "pnorm",
            mean=mean(log(ing_x_hrs)),
            sd=sd(log(ing_x_hrs)))
    )
```

```
Warning in ks.test.default(log(ing_x_hrs), "pnorm", mean =
mean(log(ing_x_hrs)), : ties should not be present for the Kolmogorov-Smirnov
test
```

```
    Asymptotic one-sample Kolmogorov-Smirnov test

data:  log(ing_x_hrs)
D = 0.081512, p-value < 2.2e-16
alternative hypothesis: two-sided
```

La prueba tiene una Ho "La variable es normal"

¿Qué hacer?

4.5.4 Kruskal-Wallis test

Hay una prueba muy parecida que se basa en el orden de las observaciones, y se lee muy parecida a la ANOVA

```
kruskal<-tlaxt322  %>%
    filter(ing_x_hrs>0) %>%
      with(
        kruskal.test(ing_x_hrs ~ as_factor(t_loc_tri))
        )
```

```
kruskal
```

```
    Kruskal-Wallis rank sum test

data:  ing_x_hrs by as_factor(t_loc_tri)
Kruskal-Wallis chi-squared = 20.933, df = 2, p-value = 2.847e-05
```

Para ver las comparaciones tenemos que usar el `DunnTest()`, del paquete `{DescTools}`

```
tlaxt322  %>%
    filter(ing_x_hrs>0) %>%
      with(
        DescTools::DunnTest(ing_x_hrs ~ as_factor(t_loc_tri))
        )
```

```
 Dunn's test of multiple comparisons using rank sums : holm

    mean.rank.diff   pval
3-2      -171.3068  3e-05 ***
4-2      -146.1191 0.0058 **
4-3        25.1877 0.5978
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4.5.4.1 Un gráfico coqueto:

Se hace con ggpubr

```
tlaxt322  %>%
  filter(clase2==1) %>%
  ggpubr::ggviolin(x = "t_loc_tri", y = "ing_x_hrs", fill = "t_loc_tri",
                   add = "boxplot", add.params = list(fill = "white")) +
  stat_compare_means(label.y = 600)  # Add the p-value
```

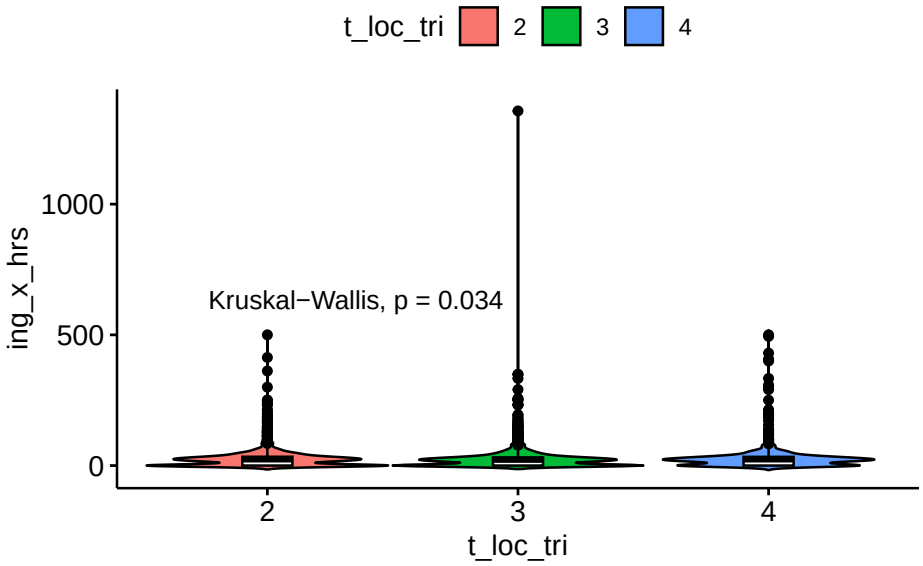


```
comparaciones <- list( c("1", "2"), c("2", "3"), c("1", "3"),
                       c("1", "4"), c("2", "4"), c("3", "4") )



#Un gráfiquito accesorio 2:

tlaxt322  %>%
  filter(clase2==1) %>%
  filter(ing_x_hrs>0) %>%
  ggpubr::ggviolin(x = "t_loc_tri", y = "ing_x_hrs", fill = "t_loc_tri",
                   palette = wesanderson::wes_palette("GrandBudapest1", 4, type="discrete
                   add = "boxplot", add.params = list(fill = "white"))+
  stat_compare_means(comparisons = comparaciones, label = "p.signif")+ # Add significance
  stat_compare_means(label.y = 500)     # Add global the p-value
```

```
[1] FALSE

Warning: Computation failed in `stat_signif()`
Caused by error in `if (scales$x$map(comp[1]) == data$group[1] | manual) ...`:
! valor ausente donde TRUE/FALSE es necesario
```

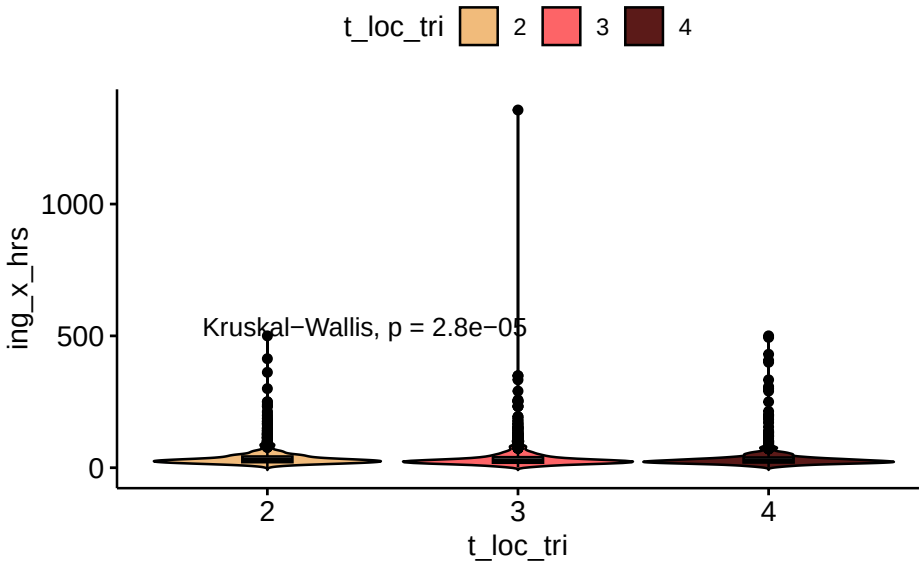
t_loc_tri
2
3
4
ing_x_hrs
1000
500
0
Kruskal−Wallis, p = 2.8e−05
2
3
4
t_loc_tri

Chapter 5

Introducción a los modelos de regresión

5.1 Paquetes

```
if (!require("pacman")) install.packages("pacman")#instala pacman si se requiere
```

```
Loading required package: pacman
```

```
pacman::p_load(tidyverse,
               readxl,
               writexl,
               haven,
               sjlabelled,
               janitor,
               infer,
               ggpubr,
               magrittr,
               gt,
               GGally,
               broom,
               DescTools,
               wesanderson,
               gtsummary,
               srvyr,
               car,
               sjPlot,
```

```
                performance, see,
                jtools, #ojo
                sandwich,
                huxtable)
```

5.2 Cargando los datos

Desde STATA y haciendo filtros para hacer el código más corto:

```
tlaxt322 <- read_dta("./datos/tlaxt322.dta") %>%
  clean_names() %>%
  filter(r_def==0) %>%
  filter(!c_res==2) %>%
  filter(ing_x_hrs>0) %>%
  filter(clase2==1) %>%
  filter(anios_esc<99) %>%
  mutate(log_ing_x_hrs=log(ing_x_hrs))
```

5.3 Introducción a la regresión lineal

La relación entre dos variables

En términos *mincerianos*, los ingresos estarían explicados por la escolaridad y la experiencia...

```
tlaxt322 %>%
  ggplot() +
  aes(x=anios_esc,
      y=log_ing_x_hrs) +
  geom_point()
```

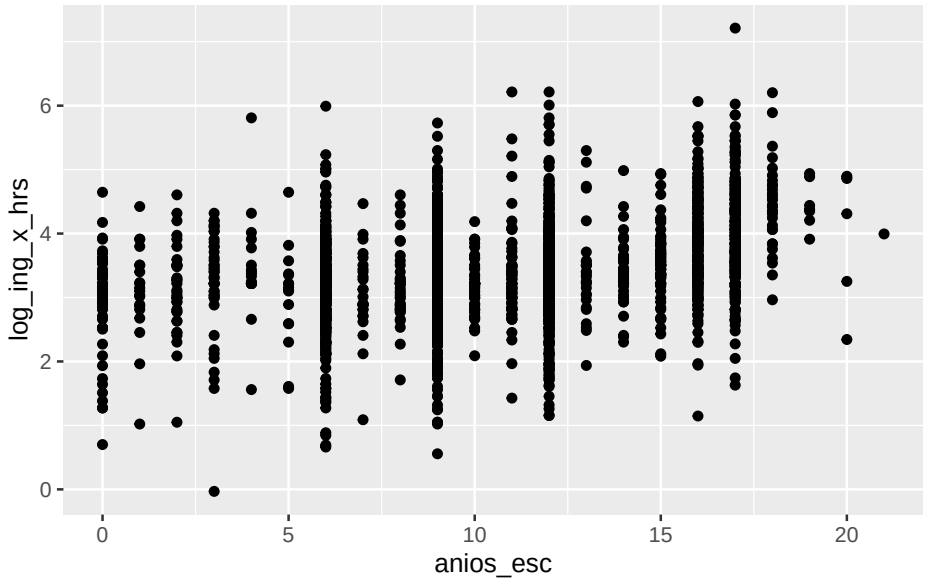

Cuando tenemos muchos casos es útil la opción "jitter"

```
tlaxt322 %>%
  ggplot() +
  aes(x=anios_esc, y=log_ing_x_hrs) +
  geom_jitter()
```

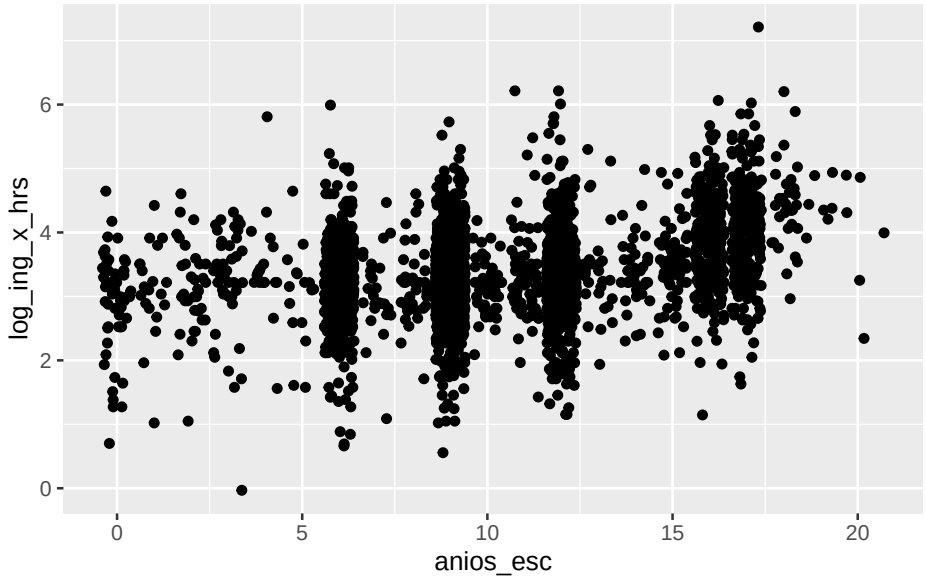

También cambiar un poquito la transparencia...

```
tlaxt322 %>%
  ggplot() +
    aes(x=anios_esc, y=log_ing_x_hrs, alpha=I(0.5)) +
  geom_jitter()
```

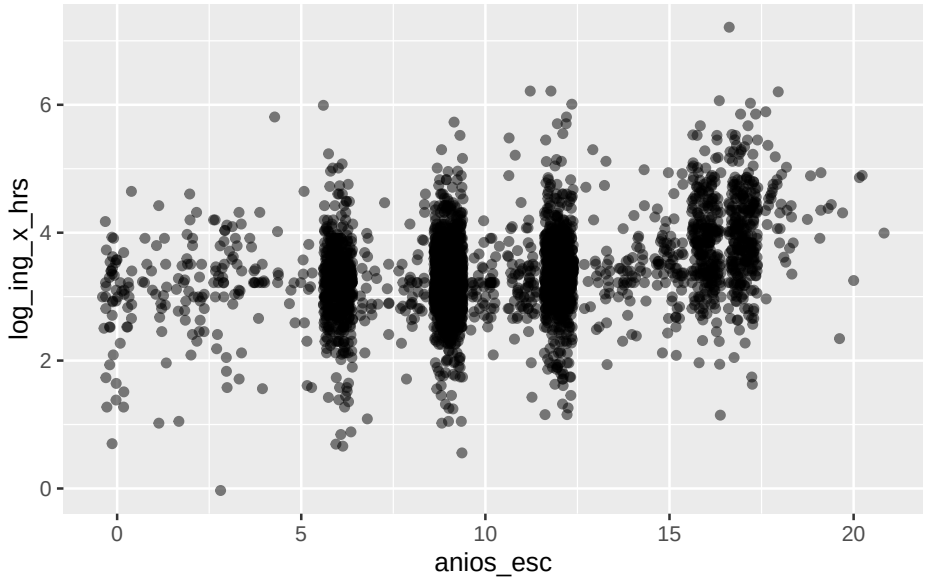

¿Cómo se ve la línea MCO ajustada por estos elementos?

```
tlaxt322 %>%
  ggplot() +
    aes(x=anios_esc, y=log_ing_x_hrs, alpha=I(0.5)) +
  geom_jitter()+
  geom_smooth(method = lm)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

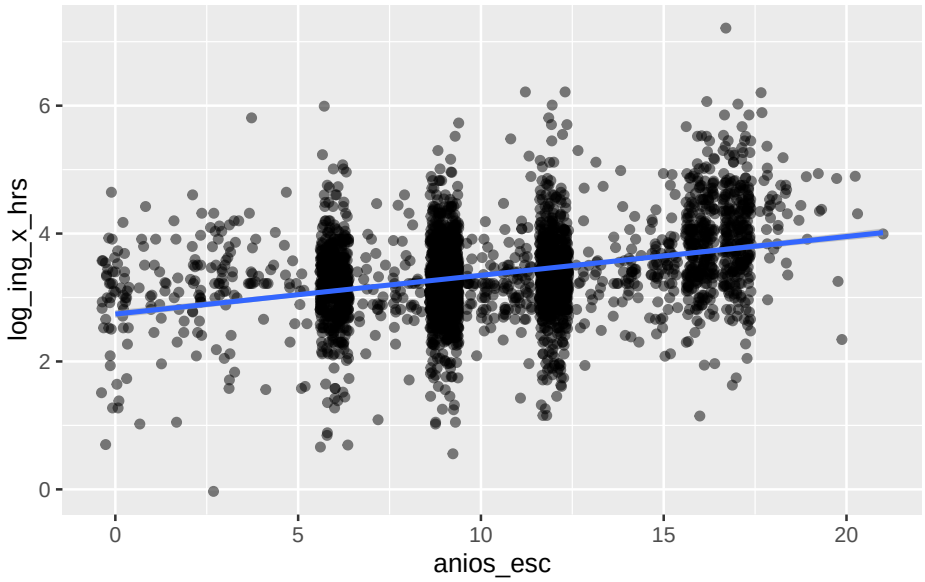

5.4 Prueba de hipótesis para la correlación

Una prueba de hipotésis sobe la correlación

```
cor_test<-tlaxt322 %>%
  with(
    cor.test(log_ing_x_hrs,
             anios_esc,
             use = "pairwise")) # prueba de hipótesis.

#dos modos de visualizar el resultado

cor_test
```

```
    Pearson's product-moment correlation

data:  log_ing_x_hrs and anios_esc
t = 21.85, df = 3626, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3120129 0.3695315
sample estimates:
      cor
```

```
0.3410914
```

```
tidy(cor_test)
```

estimate	statistic	p.value	parameter	conf.low	conf.high	method	alternative
0.341	21.8	1.59e-99	3626	0.312	0.37	Pearson's product-moment correlation	two.sided

5.5 ¿cómo se ajusta la línea?

Este sería el modelo simple

$$y = \beta_o + \beta_1 x + \epsilon$$

Donde los parámetros β_o y β_1 describen la pendiente y el intercepto de la población, respectivamente.

```
modelo<-tlaxt322 %>%
  with(
    lm(log_ing_x_hrs~ anios_esc)
  )

modelo
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc)

Coefficients:
(Intercept)    anios_esc
    2.74119      0.06062
```

Guardarlo en un objeto sirve de mucho porque le podemos "preguntar" cosas

```
summary(modelo) # da todo menos la anova de la regresión
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc)
```

```
Residuals:
    Min      1Q  Median      3Q     Max
-2.9546 -0.3556 -0.0423  0.3432  3.4410

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 2.741194   0.030334   90.37   <2e-16 ***
anios_esc   0.060619   0.002774   21.85   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6413 on 3626 degrees of freedom
Multiple R-squared:  0.1163,    Adjusted R-squared:  0.1161
F-statistic: 477.4 on 1 and 3626 DF,  p-value: < 2.2e-16
```

```r
confint(modelo) # da los intervalos de confianza
```

```
                2.5 %     97.5 %
(Intercept) 2.68172099 2.80066669
anios_esc   0.05517928 0.06605823
```

```r
anova(modelo) # esto sí da la anova de la regresión.
```

Df	Sum Sq	Mean Sq	F value	Pr(>F)
1	196	196	477	1.59e-99
3626	1.49e+03	0.411		

Para ver esto más guapo:

```r
modelo %>%
   gtsummary::tbl_regression()
```

```
Table printed with `knitr::kable()`, not {gt}. Learn why at
https://www.danieldsjoberg.com/gtsummary/articles/rmarkdown.html
To suppress this message, include `message = FALSE` in code chunk header.
```

Characteristic	Beta	95% CI	p-value
Años de escolaridad	0.06	0.06, 0.07	<0.001

```
#%>%
# add_significance_stars() %>%
# add_n() %>%
# add_glance_table()
```

5.6 Diagnósticos

```
plot(modelo)
```

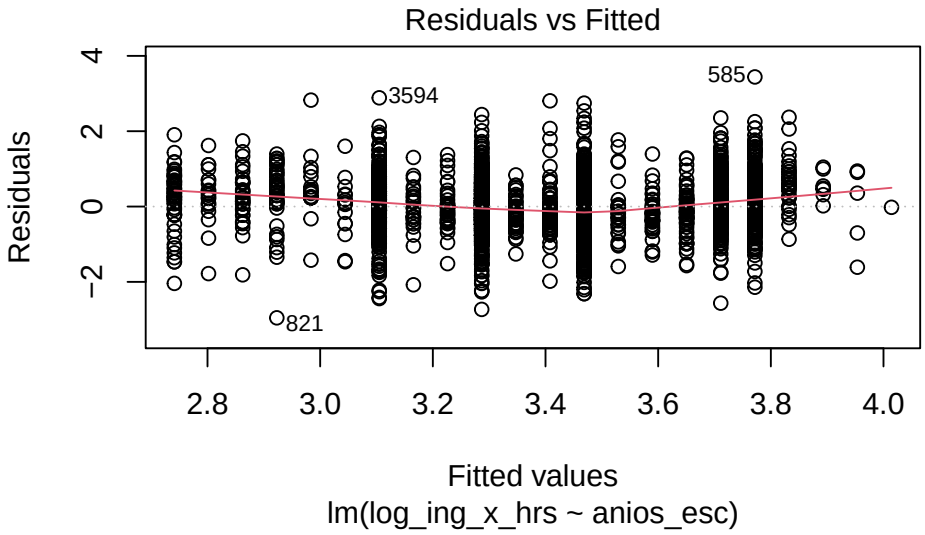

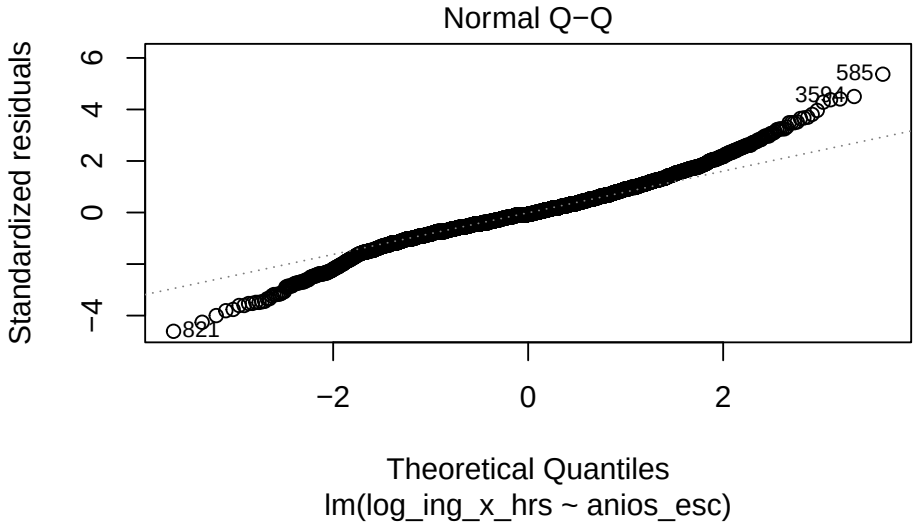
Normal Q−Q
Standardized residuals
585
821
−4
0
2
4
6
−2
0
2
Theoretical Quantiles
lm(log_ing_x_hrs ~ anios_esc)

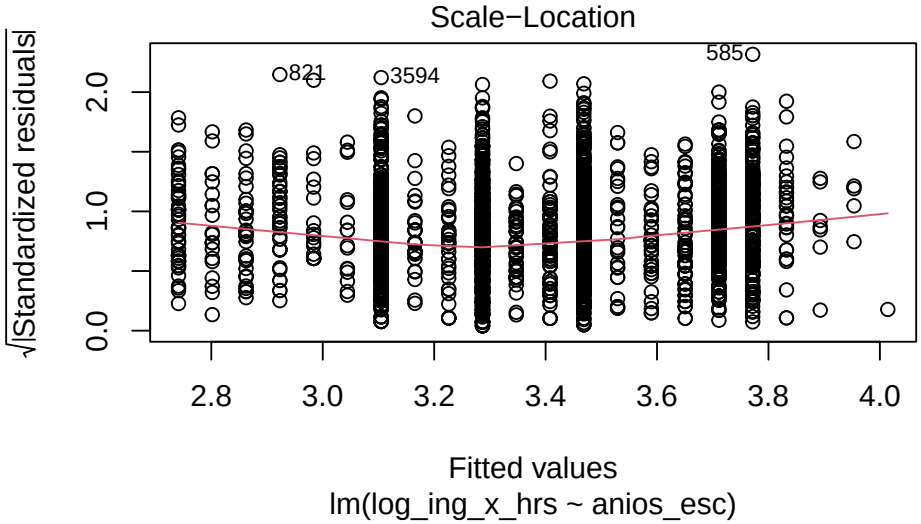
Scale−Location
√|Standardized residuals|
821
3594
585
0.0
1.0
2.0
2.8
3.0
3.2
3.4
3.6
3.8
4.0
Fitted values
lm(log_ing_x_hrs ~ anios_esc)

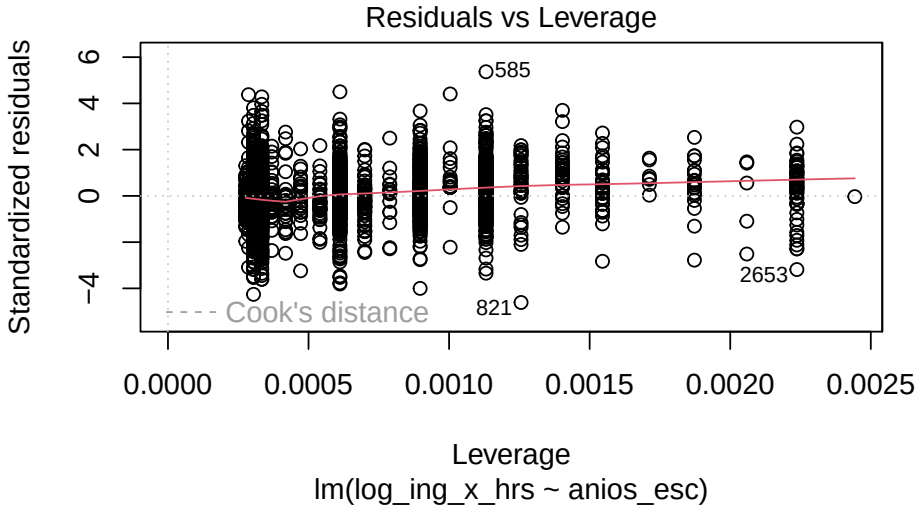

5.6.1 Outliers y Normalidad

```
# Assessing Outliers
car::outlierTest(modelo) # Bonferonni p-value for most extreme obs
```

```
     rstudent unadjusted p-value Bonferroni p
585   5.389216         7.5277e-08   0.00027311
821  -4.622756         3.9187e-06   0.01421700
3594  4.514303         6.5544e-06   0.02377900
3108  4.419125         1.0200e-05   0.03700600
3264  4.387877         1.1772e-05   0.04270900
```

```
ggpubr::ggqqplot(tlaxt322$log_ing_x_hrs)
```

```
Warning: The following aesthetics were dropped during statistical transformation: sample
i This can happen when ggplot fails to infer the correct grouping structure in
  the data.
i Did you forget to specify a `group` aesthetic or to convert a numerical
  variable into a factor?
The following aesthetics were dropped during statistical transformation: sample
i This can happen when ggplot fails to infer the correct grouping structure in
  the data.
i Did you forget to specify a `group` aesthetic or to convert a numerical
  variable into a factor?
```

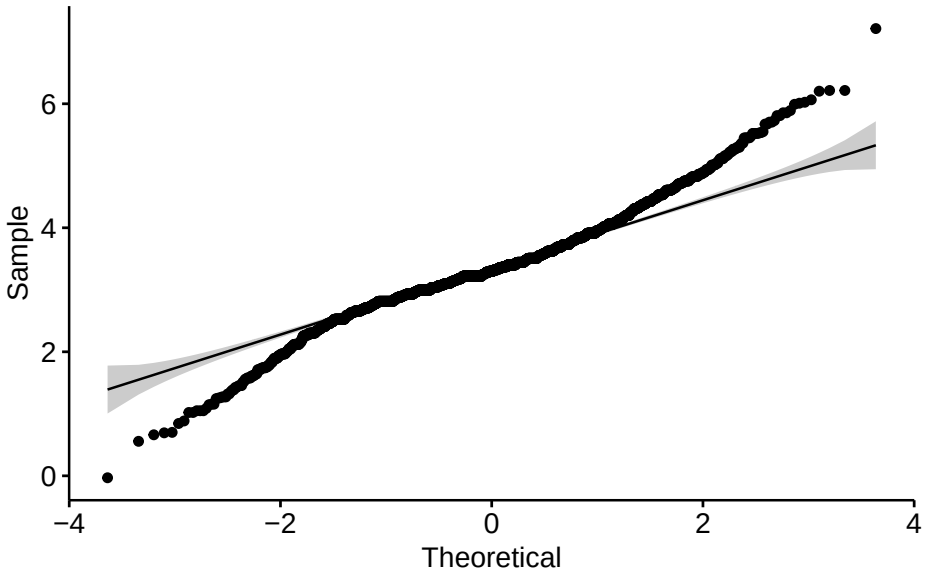

5.6.2 Homocedasticidad

```
# non-constant error variance test
car::ncvTest(modelo)
```

```
Non-constant Variance Score Test
Variance formula: ~ fitted.values
Chisquare = 13.53891, Df = 1, p = 0.00023367
```

```
# plot studentized residuals vs. fitted values
car::spreadLevelPlot(modelo)
```

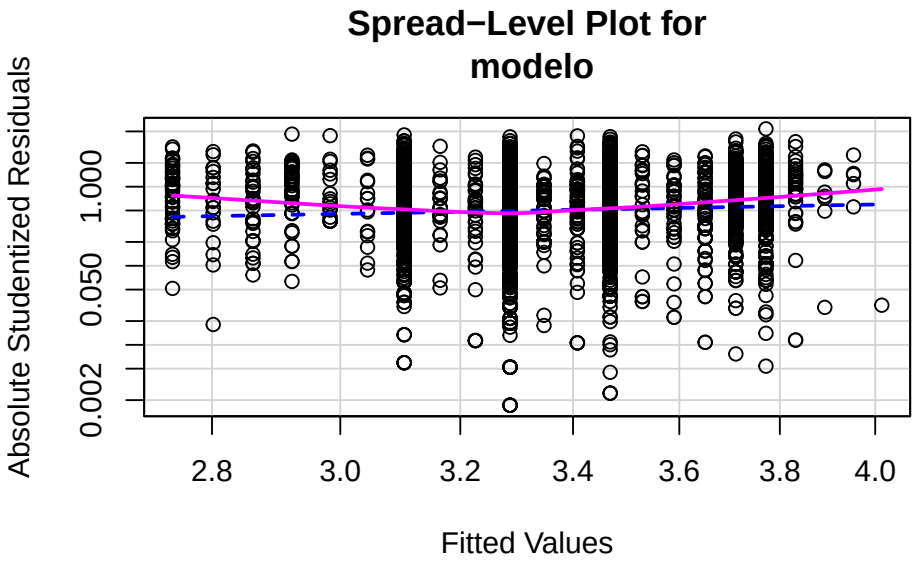


```
Suggested power transformation:  0.0476972
```

5.6.3 Con el paquete {performance}

Hay varios chequeos múltiples útiles en este paquete:

```
performance::check_model(modelo)
```

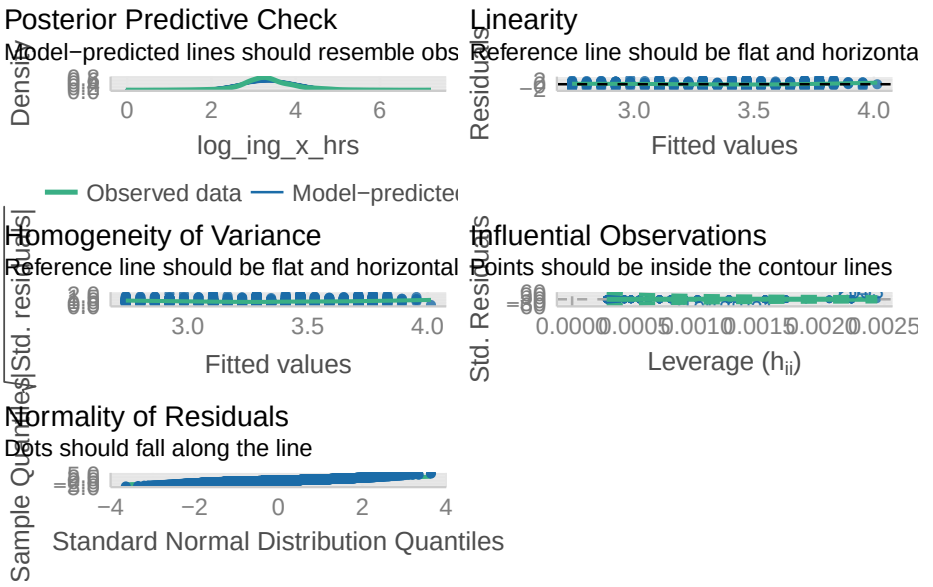

Y hacer un test de heterocedasticidad

```
performance::check_heteroscedasticity(modelo)
```

```
Warning: Heteroscedasticity (non-constant error variance) detected (p < .001).
```

5.7 Regresión Lineal múltiple

5.7.1 Agregando una variable categórica

¿Es igual la relación entre hombres y mujeres con los ingresos y la escolaridad?

```
tlaxt322 %>%
  ggplot() +
    aes(x=anios_esc, y=log_ing_x_hrs, alpha=I(0.5), color=as_label(sex)) +
  geom_jitter()+
  geom_smooth(method = lm)
```

```
`geom_smooth()` using formula = 'y ~ x'
```

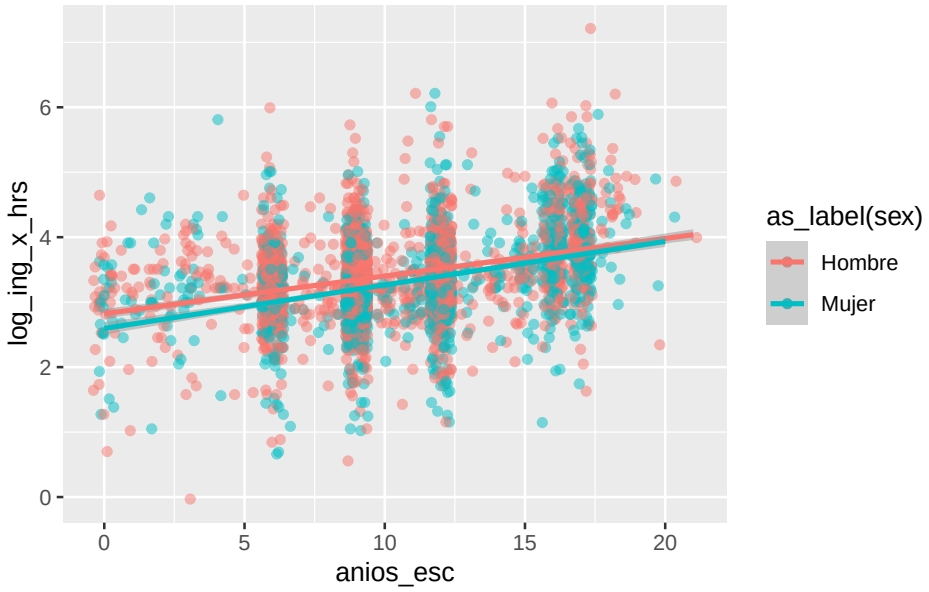

Cuando nosotros tenemos una variable categórica para la condición de sexo. [nota: seguimos haciendo el ejercicio, a pesar de que ya observamos en nuestro diagnóstico el modelo no cumple con los supuestos, pero lo haremos para fines ilustrativos]

```
modelo1<-tlaxt322 %>%
  mutate(sex = as_label(sex)) %>%
  with(
    lm(log_ing_x_hrs ~ anios_esc + sex)
  )

summary(modelo1)
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc + sex)

Residuals:
    Min      1Q  Median      3Q     Max
-2.9999 -0.3586 -0.0338  0.3492  3.3780

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.782795   0.030924   89.99  < 2e-16 ***
anios_esc    0.061881   0.002768   22.36  < 2e-16 ***
```

```
sexMujer    -0.133297   0.021606   -6.17  7.6e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6381 on 3625 degrees of freedom
Multiple R-squared:  0.1255,    Adjusted R-squared:  0.125
F-statistic: 260.2 on 2 and 3625 DF,  p-value: < 2.2e-16
```

Este modelo tiene coeficientes que deben leerse "condicionados". Es decir, en este caso tenemos que el coeficiente asociado a la edad, mantiene constante el valor de sexo y viceversa.

¿Cómo saber is ha mejorado nuestro modelo? Podemos comparar el ajuste con la anova, es decir, una prueba F

```
pruebaf0<-anova(modelo, modelo1)
pruebaf0
```

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
3.63e+03	1.49e+03				
3.62e+03	1.48e+03	1	15.5	38.1	7.6e-10

Como puedes ver, el resultado muestra un Df de 1 (lo que indica que el modelo más complejo tiene un parámetro adicional) y un valor p muy pequeño (<.51). Esto significa que agregar el sexo al modelo lleva a un ajuste significativamente mejor sobre el modelo original.

Esto también lo podemos hacer con el paquete {performance}:

```
performance::compare_performance(modelo, modelo1)
```

	Model	AIC	AIC_wt	AICc	AICc_wt	BIC	BIC_wt	R2	R2_adjusted	RMSE
	lm	7.08e+03	1.6e-08	7.08e+03	1.61e-08	7.1e+03	3.55e-07	0.116	0.116	0.641
1	lm	7.04e+03	1	7.04e+03	1	7.07e+03	1	0.126	0.125	0.638

Y también podemos hacer una prueba:

```
performance::test_performance(modelo, modelo1)
```

Name	Model	log_BF	BF	df	df_diff	Chi2	p
modelo	lm			3			
modelo1	lm	14.9	2.81e+06	4	1	37.9	7.46e-10

5.7.2 Otra variable cuantitativa

Podemos seguir añadiendo variables sólo "sumando" en la función

```
modelo2<- tlaxt322 %>%
  mutate(sex=as_label(sex)) %>%
  with(
    lm(log_ing_x_hrs ~ anios_esc + sex + eda)
    )
summary(modelo2)
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc + sex + eda)

Residuals:
    Min      1Q  Median      3Q     Max
-3.0735 -0.3431 -0.0291  0.3461  3.3376

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.5277184  0.0484577  52.163  < 2e-16 ***
anios_esc    0.0669698  0.0028505  23.494  < 2e-16 ***
sexMujer    -0.1367690  0.0214777  -6.368 2.16e-10 ***
eda          0.0052229  0.0007671   6.808 1.15e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6341 on 3624 degrees of freedom
Multiple R-squared:  0.1366,    Adjusted R-squared:  0.1359
F-statistic: 191.1 on 3 and 3624 DF,  p-value: < 2.2e-16
```

Y podemos ver si introducir esta variable afectó al ajuste global del modelo

```
pruebaf1<-anova(modelo1, modelo2)
pruebaf1
```

Hoy que tenemos más variables podemos hablar de revisar dos supuestos más.

Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
3.62e+03	1.48e+03				
3.62e+03	1.46e+03	1	18.6	46.4	1.15e-11

5.7.3 Otros supuestos

Además de los supuestos de la regresión simple, podemos revisar estos otros. De nuevo, usaremos el paquete `{car}`

1. Linealidad en los parámetros (será más díficil entre más variables tengamos)
2. La normalidad también, porque debe ser multivariada
3. Multicolinealidad La prueba más común es la de Factor Influyente de la Varianza (VIF) por sus siglas en inglés. La lógica es que la multicolinealidad tendrá efectos en nuestro R2, inflándolo. De ahí que observamos de qué variable(s) proviene este problema relacionado con la multicolinealidad.

Si el valor es mayor a 5, tenemos un problema muy grave.

```
car::vif(modelo2)
```

```
anios_esc       sex       eda
 1.079735  1.006061  1.073849
```

5.7.4 Paquete `{jtools}`

Un solo modelo:

```
jtools::summ(modelo)
```

Observations	3628
Dependent variable	log_ing_x_hrs
Type	OLS linear regression

Si queremos errores robusto, estilo *STATA*:

F(1,3626)	477.40
R^2	0.12
Adj. R^2	0.12

	Est.	S.E.	t val.	p
(Intercept)	2.74	0.03	90.37	0.00
anios_esc	0.06	0.00	21.85	0.00

Standard errors: OLS

```
summ(modelo2,  robust = "HC1")
```

Observations	3628
Dependent variable	log_ing_x_hrs
Type	OLS linear regression

F(3,3624)	191.07
R^2	0.14
Adj. R^2	0.14

	Est.	S.E.	t val.	p
(Intercept)	2.53	0.05	50.79	0.00
anios_esc	0.07	0.00	20.56	0.00
sexMujer	-0.14	0.02	-6.32	0.00
eda	0.01	0.00	6.39	0.00

Standard errors: Robust, type = HC1

Si queremos estandarizar nuestras escalas:

```
summ(modelo2,  scale=T)
```

Observations	3628
Dependent variable	log_ing_x_hrs
Type	OLS linear regression

F(3,3624)	191.07
R^2	0.14
Adj. R^2	0.14

	Est.	S.E.	t val.	p
(Intercept)	3.42	0.01	249.25	0.00
anios_esc	0.26	0.01	23.49	0.00
sexMujer	-0.14	0.02	-6.37	0.00
eda	0.07	0.01	6.81	0.00

Standard errors: OLS; Continuous predictors are mean-centered and scaled by 1 s.d.

También se pueden comparar modelos:

```
export_summs(modelo, modelo1, modelo2)
```

	Model 1	Model 2	Model 3
(Intercept)	2.74 ***	2.78 ***	2.53 ***
	(0.03)	(0.03)	(0.05)
anios_esc	0.06 ***	0.06 ***	0.07 ***
	(0.00)	(0.00)	(0.00)
sexMujer		-0.13 ***	-0.14 ***
		(0.02)	(0.02)
eda			0.01 ***
			(0.00)
N	3628	3628	3628
R2	0.12	0.13	0.14

*** p < 0.001; ** p < 0.01; * p < 0.05.

También el paquete "sjPlot" tiene el comando "plot_model()"

```
sjPlot::plot_model(modelo1)
```

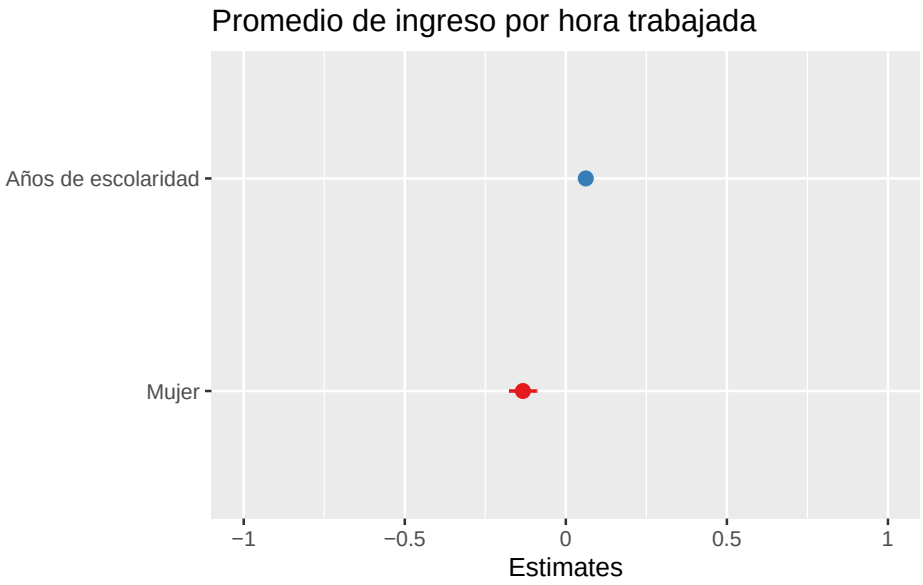


```
sjPlot::plot_models(modelo, modelo1, modelo2)
```

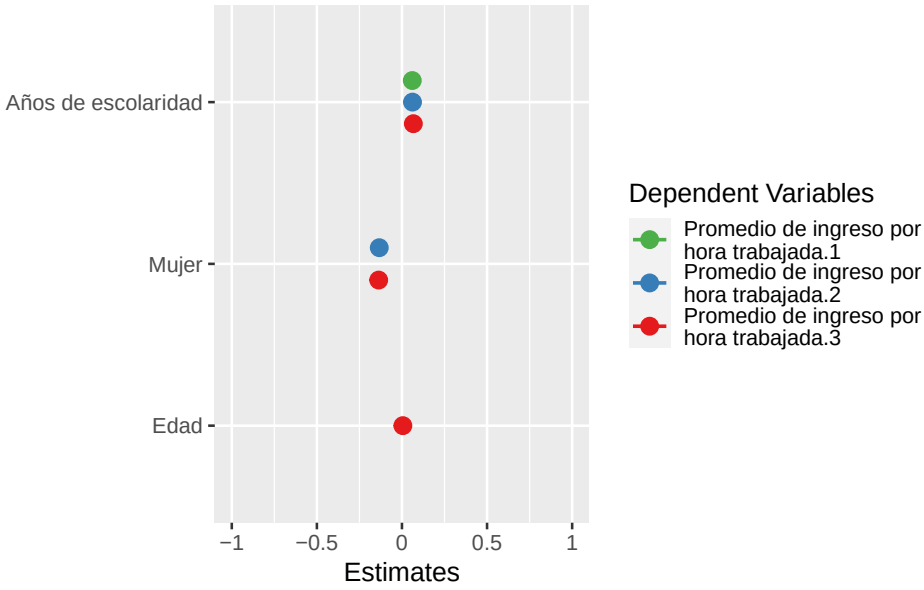

5.8 Post-estimación

5.8.1 Las predicciones

Unos de los usos más comunes de los modelos estadísticos es la predicción

```
sjPlot::plot_model(modelo2, type="pred", terms = "anios_esc")
```

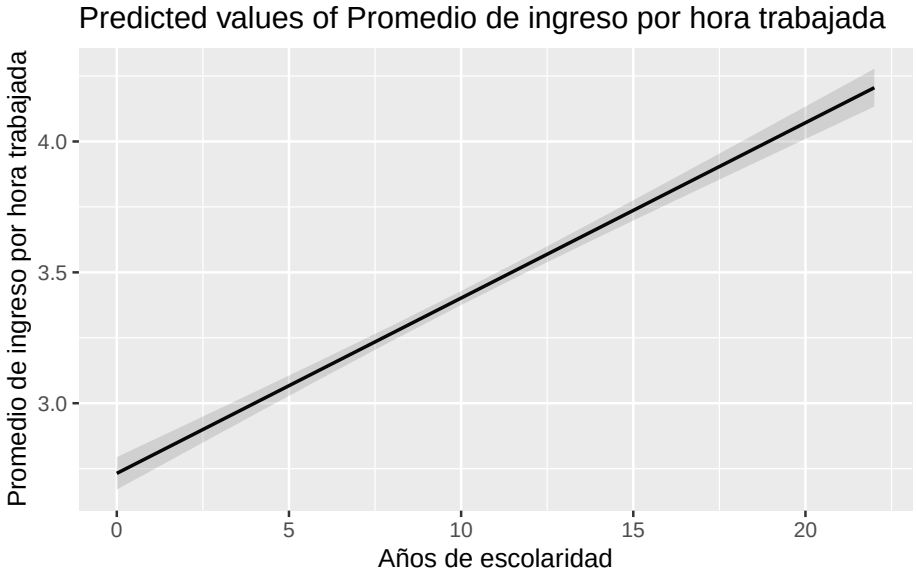

También podemos incluir la predecciones para los distintos valores de las variables

```
plot_model(modelo2, type="pred", terms = c("anios_esc","sex")) + theme_blank()
```

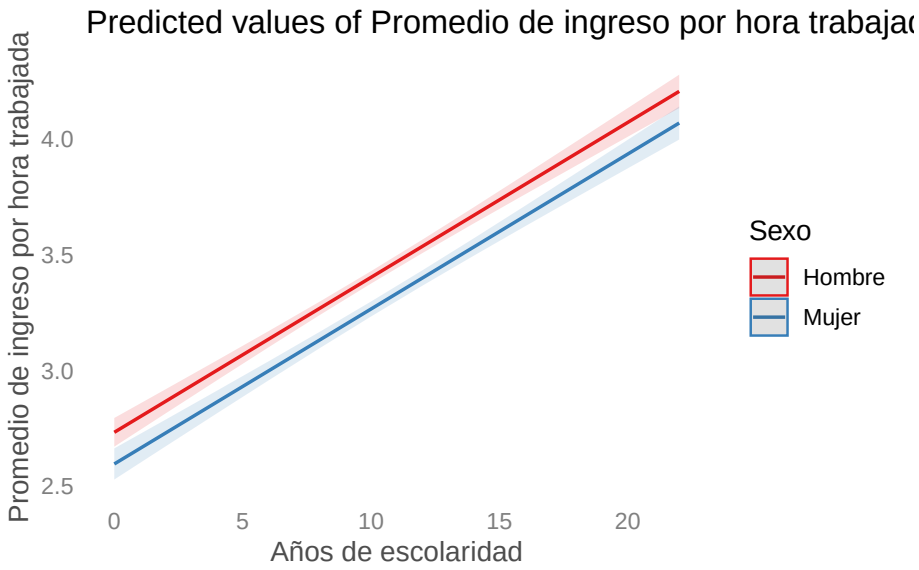

El orden de los términos importa:

```
plot_model(modelo2, type="pred", terms = c("sex","anios_esc")) + theme_blank()
```

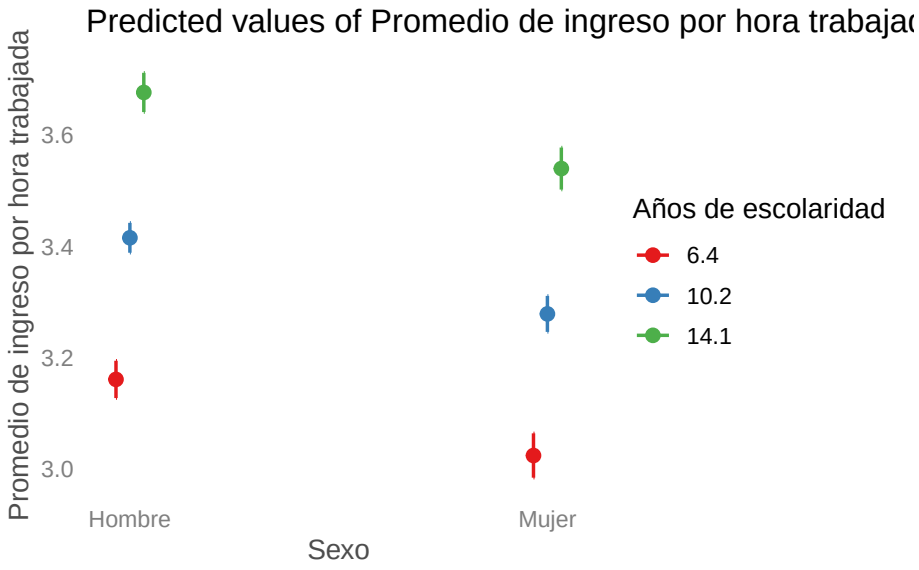

5.8.2 Efectos marginales

Con los efectos marginales, por otro lado medimos el efecto promedio, dejando el resto de variables constantes.

```
plot_model(modelo2, type="eff", terms = "anios_esc")
```

```
Package `effects` is not available, but needed for `ggeffect()`. Either
  install package `effects`, or use `ggpredict()`. Calling `ggpredict()`
  now.
```

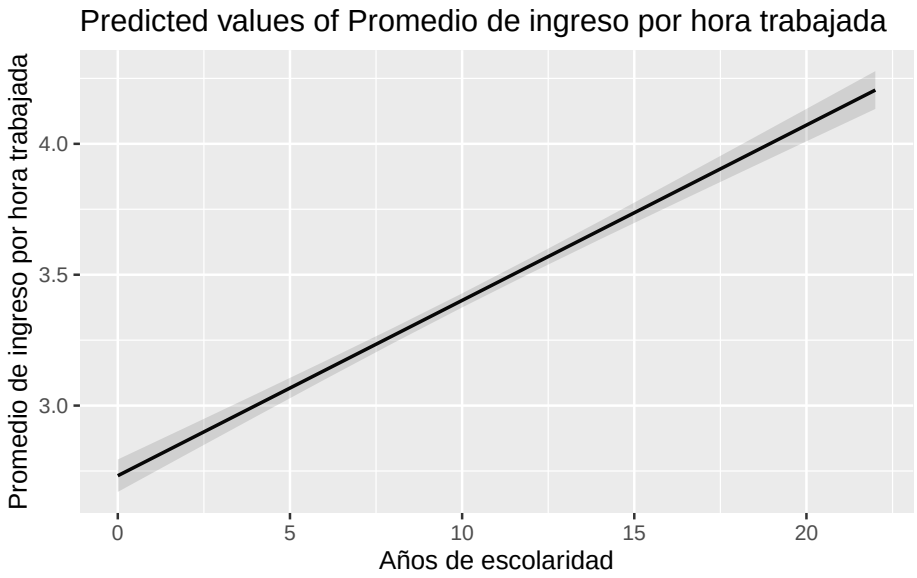


```
plot_model(modelo2, type="eff", terms = "sex")
```

```
Package `effects` is not available, but needed for `ggeffect()`. Either
  install package `effects`, or use `ggpredict()`. Calling `ggpredict()`
  now.
```

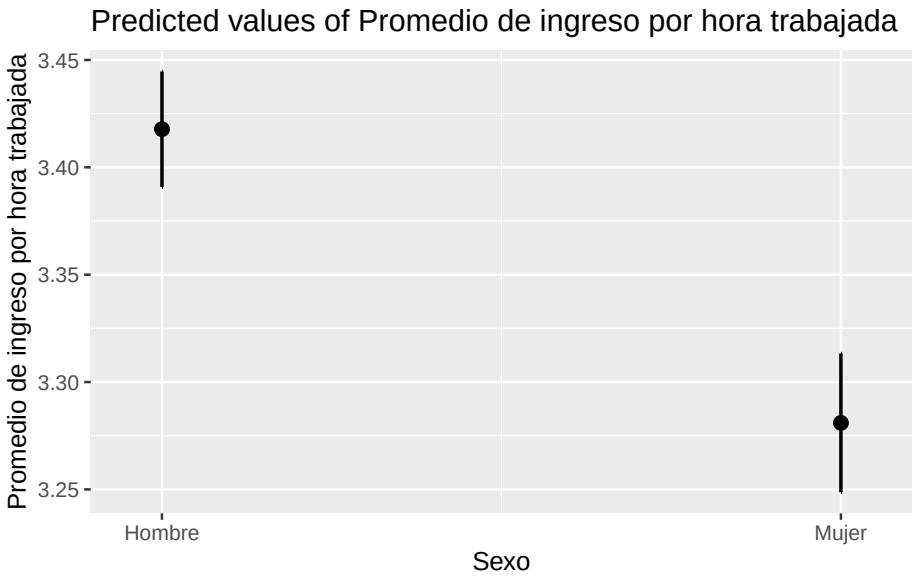

¿Es el mismo gráfico que con "pred"? Veamos la ayuda

¿Y si queremos ver esta informaicón graficada?

```
eff<-plot_model(modelo2, type="eff", terms = "anios_esc")
```

```
Package `effects` is not available, but needed for `ggeffect()`. Either
  install package `effects`, or use `ggpredict()`. Calling `ggpredict()`
  now.
```

```
eff$data
```

```
eff<-plot_model(modelo2, type="pred", terms = "anios_esc")
eff$data
```

5.9 Extensiones del modelo de regresión

5.9.1 Introducción a las interacciones

Muchas veces las variables explicativas van a tener relación entre sí. Por ejemplo ¿Las horas tendrá que ver con el sexo y afectan no sólo en intercepto si no también la pendiente? Para ello podemos introducir una interacción

x	predicted	std.error	conf.low	conf.high	group	group__col
0	2.73	0.0316	2.67	2.79	1	1
2	2.87	0.0266	2.81	2.92	1	1
4	3	0.0219	2.96	3.04	1	1
6	3.13	0.0178	3.1	3.17	1	1
8	3.27	0.0148	3.24	3.3	1	1
10	3.4	0.0137	3.37	3.43	1	1
12	3.54	0.0148	3.51	3.56	1	1
14	3.67	0.0178	3.63	3.7	1	1
16	3.8	0.0219	3.76	3.85	1	1
18	3.94	0.0266	3.89	3.99	1	1
20	4.07	0.0316	4.01	4.13	1	1
22	4.21	0.0368	4.13	4.28	1	1

```
modelo_int1<-lm(log_ing_x_hrs ~ anios_esc * sex , data = tlaxt322, na.action=na.exclude)
summary(modelo_int1)
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc * sex, data = tlaxt322,
    na.action = na.exclude)

Residuals:
    Min      1Q  Median      3Q     Max
-3.0278 -0.3584 -0.0289  0.3452  3.4058

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    3.049566   0.091903  33.182  < 2e-16 ***
anios_esc      0.048830   0.008487   5.754 9.46e-09 ***
sex           -0.226965   0.061500  -3.691 0.000227 ***
anios_esc:sex  0.009071   0.005577   1.627 0.103888
---
```

x	predicted	std.error	conf.low	conf.high	group	group_col
0	2.73	0.0316	2.67	2.79	1	1
2	2.87	0.0266	2.81	2.92	1	1
4	3	0.0219	2.96	3.04	1	1
6	3.13	0.0178	3.1	3.17	1	1
8	3.27	0.0148	3.24	3.3	1	1
10	3.4	0.0137	3.37	3.43	1	1
12	3.54	0.0148	3.51	3.56	1	1
14	3.67	0.0178	3.63	3.7	1	1
16	3.8	0.0219	3.76	3.85	1	1
18	3.94	0.0266	3.89	3.99	1	1
20	4.07	0.0316	4.01	4.13	1	1
22	4.21	0.0368	4.13	4.28	1	1

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6379 on 3624 degrees of freedom
Multiple R-squared:  0.1262,    Adjusted R-squared:  0.1254
F-statistic: 174.4 on 3 and 3624 DF,  p-value: < 2.2e-16
```

Esta interacción lo que asume es que las pendientes pueden moverse (aunque en este caso específico no lo hacen tanto porque no nos salió significativa)

```
plot_model(modelo_int1, type="int", terms = c("sex", "anios_esc"))
```

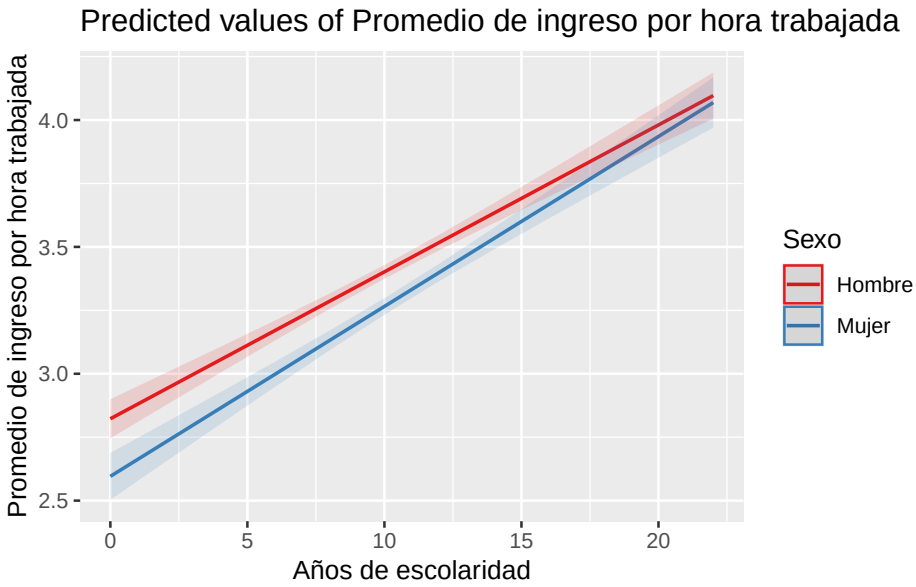

5.9.2 Efectos no lineales

5.9.2.1 Explicitando el logaritmo

```
modelo_log<-tlaxt322 %>%
  with(
    lm(log(ing_x_hrs) ~ log(eda) + sex))

summary(modelo_log)
```

```
Call:
lm(formula = log(ing_x_hrs) ~ log(eda) + sex)

Residuals:
    Min      1Q  Median      3Q     Max
-3.4773 -0.3734 -0.0570  0.3443  3.8024

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  3.18608    0.11087  28.737  < 2e-16 ***
log(eda)     0.08762    0.02949   2.971  0.00299 **
sex         -0.09897    0.02296  -4.310 1.67e-05 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6798 on 3625 degrees of freedom
Multiple R-squared:  0.007366,  Adjusted R-squared:  0.006818
F-statistic: 13.45 on 2 and 3625 DF,  p-value: 1.516e-06
```

```r
plot_model(modelo_log, type="pred", terms ="eda")
```

```
Model has log-transformed response. Back-transforming predictions to
  original response scale. Standard errors are still on the log-scale.
```

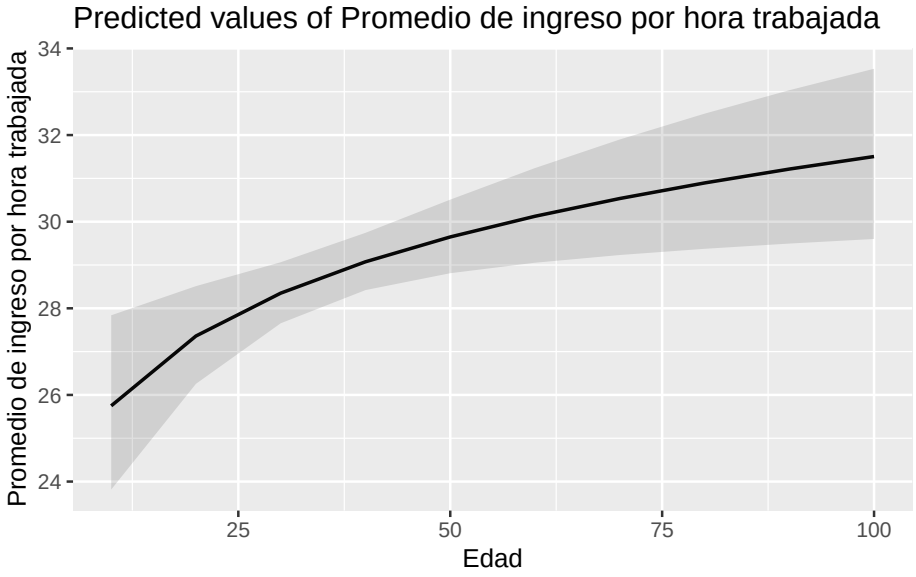

5.9.2.2 Efecto cuadrático (ojo con la sintaxis)

```r
modelo_quadr<-lm(log_ing_x_hrs ~ anios_esc + I(anios_esc^2) + sex,
                 data=tlaxt322)
summary(modelo_quadr)
```

```
Call:
lm(formula = log_ing_x_hrs ~ anios_esc + I(anios_esc^2) + sex,
    data = tlaxt322)
```

```
Residuals:
    Min      1Q  Median      3Q     Max
-3.2111 -0.3427 -0.0236  0.3345  3.2133

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)     3.4198227  0.0627084  54.535  < 2e-16 ***
anios_esc      -0.0485443  0.0107916  -4.498 7.06e-06 ***
I(anios_esc^2)  0.0053554  0.0005064  10.576  < 2e-16 ***
sex            -0.1428121  0.0213016  -6.704 2.34e-11 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6285 on 3624 degrees of freedom
Multiple R-squared:  0.1517,    Adjusted R-squared:  0.151
F-statistic:   216 on 3 and 3624 DF,  p-value: < 2.2e-16
```

Quizás con un gráfico de lo predicho tenemos más claro lo que hace ese término

```r
plot_model(modelo_quadr, type="pred", terms = c("anios_esc"))
```

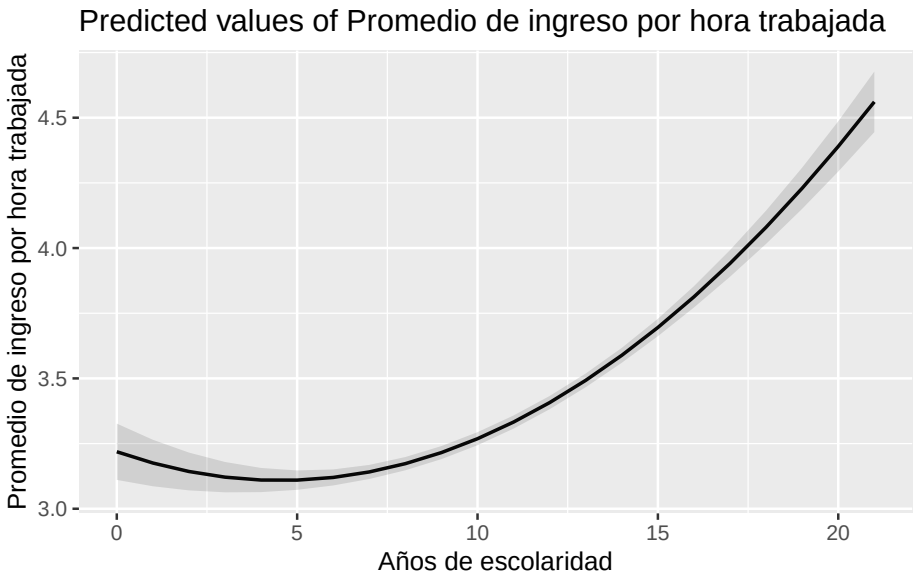

Material anexo

Lista general de YouTube

https://www.youtube.com/playlist?list=PLDnSa5YhrAVlczarJEzgR_bxFGbg9MGEU

Scripts

Los scripts están en esta carpeta: https://github.com/aniuxa/posgrado_modelo3/tree/main/scripts

Cuestionarios

Primer cuestionario

Después de la sesión 1 y 2

Cuestionario

Segundo cuestionario

Después de la sesión 3 y 4

Cuestionario

Sesión 1

Video

https://youtu.be/D4KgiEX7rB8

Cheat Sheets

- RStudio IDE: https://raw.githubusercontent.com/rstudio/cheatsheets/main/rstudio-ide.pdf
- dplyr: https://raw.githubusercontent.com/rstudio/cheatsheets/main/data-transformation.pdf

Sesión 2

Video

https://youtu.be/6aOjB4zJElg

Cheat Sheets

- ggplot2: https://raw.githubusercontent.com/rstudio/cheatsheets/main/data-visualization.pdf

Sesión 3

Video

https://youtu.be/B51jPamdySw

Sesión 4

Video

https://youtu.be/g68kbzGLwp4